Sesión 2

Análisis Exploratorio y Feature Engineering

Carlos César Sánchez Coronel

MACHINE LEARNING

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

EDA como proceso detectivesco

Filosofía de John Tukey

"Escuchar a los datos" mediante visualización y estadísticas robustas antes de modelar.

Objetivo del Feature Engineering

Traducir hallazgos en características matemáticas que maximicen el rendimiento de los algoritmos.

- Juntos, EDA y Feature Engineering determinan el límite superior del rendimiento de cualquier modelo.

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Estadísticas descriptivas robustas

Clásicas (sensibles a outliers)

- Media: $\bar{x} = \frac{1}{n}\sum x_i$
- Desviación estándar: $s = \sqrt{\frac{1}{n-1}\sum(x_i - \bar{x})^2}$

Robustas (resistentes)

- Mediana: $Median = x_{(n/2)}$
- MAD: $MAD = median(|x_i - median(x)|)$

¿Cuándo usar robustas?

Cuando hay asimetría o outliers. Ej: salarios (media ¿ mediana $\rightarrow$ sesgo derecho).

Detección de outliers con z-score modificado

Z-score modificado (basado en MAD)

$$M_i = \frac{0{,}6745(x_i - \text{mediana}(x))}{\text{MAD}}$$

- Factor 0.6745 hace consistente la MAD con la desviación estándar en datos normales.
- Umbral típico: $|M_i| > 3{,}5$ indica outlier.

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Histograma y KDE

Histograma

- Ancho de bin óptimo (Freedman-Diaconis):

$$\text{ancho} = 2 \cdot \text{IQR} \cdot n^{-1/3}$$

- Útil para distribuciones con colas pesadas.

KDE (Kernel Density Estimation)

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

- h: ancho de banda (controla suavizado).
- K: kernel (gaussiano por defecto).

ECDF y Mapas de calor de correlación

ECDF (Empirical CDF)

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_{x_i \leq x}$$

Muestra la proporción acumulada. Útil para comparar distribuciones.

Correlación de Pearson y Spearman

Pearson: relación lineal.
Spearman: relación monótona (basada en rangos).

Mapa de calor: visualiza multicolinealidad.

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Métodos univariados: IQR y z-score modificado

Regla del IQR

- IQR = Q3 – Q1
- Límites: $[Q1 - 1{,}5 \cdot IQR,\ \ Q3 + 1{,}5 \cdot IQR]$
- Limitación: asume simetría; no detecta outliers contextuales.

Ejemplo práctico: detección de fraudes

En montos de transacciones, aplicar IQR por separado puede no detectar un monto normal en horario inusual. Para eso necesitamos métodos multivariados.

Métodos multivariados (I)

Distancia de Mahalanobis

$$D_M(x) = \sqrt{(x-\mu)^T \Sigma^{-1} (x-\mu)}$$

- Considera correlaciones entre variables.
- Asume normalidad multivariante.
- Se considera outlier si $D_M^2 > \chi^2_{p,0,975}$.

Métodos multivariados (II)

LOF (Local Outlier Factor)

Compara densidad local con vecinos.

$$LOF(p) = \frac{\frac{1}{k}\sum_{o \in N_k(p)} lrd(o)}{lrd(p)}$$

LOF $\gg 1$ indica outlier local.

Isolation Forest

Aísla puntos con particiones aleatorias.

- Outliers requieren menos particiones.
- Puntuación de anomalía: $s(x) = 2^{-\frac{E(h(x))}{c(n)}}$.
- $s \approx 1 \rightarrow$ anomalía.

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Mecanismos de ausencia

MCAR

Falta completamente al azar (ej. error de transcripción).

MAR

Falta al azar condicionado a otras variables (ej. mujeres no responden ingresos).

MNAR

Falta no al azar (depende del valor faltante mismo, ej. altos ingresos no declaran).

Importancia

Identificar el mecanismo ayuda a elegir la imputación adecuada. Ignorar MNAR sesga estimaciones.

Imputación simple vs múltiple

Imputación simple

- Media/mediana: rápido, subestima varianza.
- Regresión: usa otras variables.
- kNN: promedio de vecinos.

Imputación múltiple (MICE)

- Genera m conjuntos (ej. 5-10) mediante modelos iterativos.
- Combina resultados con reglas de Rubin.
- Incorpora incertidumbre de la imputación.

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Normalización, estandarización y escalado robusto

Normalización (Min-Max)	Estandarización (Z-score)	Escalado robusto
$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \in [0, 1]$	$x' = \frac{x - \mu}{\sigma}$	$x' = \frac{x - \text{mediana}}{IQR}$

- SVM y PCA requieren estandarización.
- Escalado robusto: preferible cuando hay outliers.

Transformaciones para asimetría

Logarítmica

$x' = \log(x)$ para datos positivos con cola derecha.

Yeo-Johnson

Extensión de Box-Cox que acepta valores negativos.

Box-Cox

$$x' = \begin{cases} \frac{x^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \log(x) & \lambda = 0 \end{cases}$$

Requiere $x > 0$.

Términos polinomiales e interacciones

Polinomiales

x^2, x^3 capturan relaciones no lineales. Cuidado con overfitting.

Interacciones

$x_i \cdot x_j$ modelan sinergias. Ejemplo: en precios de viviendas, la interacción entre metros cuadrados y número de habitaciones puede ser más informativa.

Binning y discretización

Igual ancho

Divide el rango en intervalos fijos. Sensible a outliers.

Igual frecuencia

Intervalos con igual número de observaciones. Mejor para distribuciones asimétricas.

- Discretizar pierde información, pero puede mejorar la robustez.

Variables temporales y agregadas

Rezagos y ventanas móviles

- y_{t-1}, y_{t-2}: dependencia temporal.
- Media móvil: $MA_t = \frac{1}{k}\sum_{i=0}^{k-1} y_{t-i}$
- Desviación móvil: volatilidad.

Codicación cíclica (hora, día)

$$\sin\left(\frac{2\pi \cdot \text{hora}}{24}\right), \quad \cos\left(\frac{2\pi \cdot \text{hora}}{24}\right)$$

Evita la discontinuidad entre 23h y 0h.

Variables agregadas por grupo

Agregaciones por cliente/usuario

- Media, desviación, conteo, min, max, etc.
- Ejemplo: en detección de fraude, frecuencia de transacciones en últimas 24h, monto promedio, etc.

¡Cuidado con el data leakage!

Usar ventanas temporales: solo datos anteriores al momento de predicción.

Codificación de alta cardinalidad

One-hot encoding

Crea muchas columnas. No escalable a cientos de categorías.

Target encoding

Reemplaza categoría por media de la variable objetivo. ¡Requiere validación cruzada para evitar leakage!

Frequency encoding

Reemplaza por frecuencia de aparición. Útil en NLP.

Weight of Evidence (WoE) para clasificación binaria

$$WoE = \ln\left(\frac{\%eventos}{\%noeventos}\right)$$

Métodos de selección

Filtro

- Correlación
- ANOVA (F-test)
- Información mutua: $I(X;Y) = \sum p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$

Wrapper

- Selección hacia adelante
- Eliminación hacia atrás
- Costosos pero pueden encontrar interacciones.

Embedded

- Importancia de árboles (Random Forest)
- Regularización L1 (Lasso): $\text{mín} \sum (y - X\beta)^2 + \lambda \sum |\beta_j|$

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Pipelines en scikit-learn

Ventajas

- Evitan data leakage (transformaciones solo en entrenamiento).
- Facilitan validación cruzada y búsqueda de hiperparámetros.
- Garantizan reproducibilidad.

Ejemplo

Pipeline con pasos: imputación, escalado, selección de características y modelo final.

Feature engineering automático

Deep Feature Synthesis (Featuretools)

Genera automáticamente características a partir de relaciones entre tablas (agregaciones, transformaciones).

- Útil para datos relacionales (clientes, transacciones, productos).
- Precaución: limitar profundidad y usar selección posterior para evitar cientos de características irrelevantes.

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Caso 1: Predicción de precios de viviendas

- **EDA**: Detectar asimetría en precio (aplicar log), outliers en área (IQR), correlaciones altas (eliminar redundantes).
- **Feature engineering**: Interacciones (habitaciones $\times$ baños), variables temporales (año de construcción transformado con Box-Cox), target encoding de ubicación, escalado robusto.

Caso 2: Detección de fraude financiero

EDA:

- Histogramas de montos (log scale)
- Boxplots por hora y día
- Mapas de calor de transacciones por ubicación

Feature engineering específico:

- Log del monto
- Variables temporales cíclicas
- Agregadas por usuario (frecuencia, monto promedio, desviación en últimas 24h)
- Distancia geográfica y temporal entre transacciones consecutivas
- Puntuación de anomalía de Isolation Forest como característica

Codificación: Target encoding con validación cruzada para tipo de comercio y ubicación.
Manejo de desbalance: SMOTE o pesos en pérdida.
Pipeline: Usar ventanas temporales para evitar leakage.
Métricas: AUC-ROC, precisión, recall, y en producción A/B test con tasa de fraude detectado.

Contenido

1. Introducción: El arte detectivesco del EDA
2. Estadísticas robustas vs clásicas
3. Visualizaciones avanzadas
4. Detección de outliers avanzada
5. Manejo de datos faltantes
6. Feature Engineering Avanzado
   - Transformaciones de variables
   - Creación de nuevas características
   - Codificación de variables categóricas
   - Selección de características
7. Pipelines y automatización
8. Casos de uso integrados
9. Conclusión

Resumen de la sesión

Lo que hemos visto

- Estadísticas robustas vs clásicas (media/mediana, MAD).
- Visualizaciones avanzadas: KDE, ECDF, mapas de calor.
- Detección de outliers: IQR, Mahalanobis, LOF, Isolation Forest.
- Manejo de datos faltantes: MCAR/MAR/MNAR, MICE.
- Transformaciones: estandarización, Box-Cox, Yeo-Johnson.
- Creación de características: polinomiales, interacciones, binning, variables temporales y agregadas.
- Codificación de categóricas: target encoding, WoE.
- Selección de características: filtro, wrapper, embedded.
- Pipelines y automatización (Featuretools).
- Casos prácticos: viviendas y fraude.

¡Gracias!