Sesión 6
ÁRBOLES DE DECISIÓN Y RANDOM FOREST

Modelos interpretables y ensambles basados en bagging

Por
Carlos César Sánchez Coronel

2026

Índice general

Índice general **1**

1. Árboles de Decisión y Random Forest **2**
1.1. Logro de la sesión . . . 2
1.2. Introducción: modelos basados en reglas . . . 2
1.3. Árboles de Decisión . . . 3
1.3.1. Estructura de un árbol . . . 3
1.3.2. Criterios de división . . . 3
1.3.3. Ejemplo práctico: cálculo de Gini . . . 4
1.3.4. Proceso de construcción: algoritmo de Hunt . . . 4
1.3.5. Sobreajuste y poda . . . 5
1.3.6. Ventajas y desventajas de los árboles . . . 5
1.4. Random Forest . . . 5
1.4.1. Intuición: combinar múltiples árboles . . . 5
1.4.2. Bootstrap aggregating (Bagging) . . . 5
1.4.3. Aleatoriedad adicional: selección de características . . . 6
1.4.4. Error Out-of-Bag (OOB) . . . 6
1.4.5. Hiperparámetros principales . . . 7
1.4.6. Importancia de características . . . 7
1.4.7. Ventajas y desventajas de Random Forest . . . 7
1.5. Comparación de métricas y criterios de selección . . . 7
1.5.1. Clasificación: precisión, recall, F1 y AUC . . . 7
1.5.2. Regresión: RMSE vs. MAE . . . 8
1.5.3. Importancia de la interpretabilidad . . . 8
1.6. Casos de uso integrados . . . 9
1.6.1. Detección de fraudes en tarjetas de crédito . . . 9
1.6.2. Análisis de riesgo crediticio . . . 9
1.6.3. Predicción de precios de viviendas (regresión) . . . 9
1.7. Implementación en scikit-learn . . . 10
1.7.1. Árbol de decisión . . . 10
1.7.2. Random Forest . . . 10
1.8. Conexión con el resto del curso . . . 10
1.9. Resumen . . . 11

Capítulo 1

Árboles de Decisión y Random Forest

En esta sesión se aborda uno de los modelos más intuitivos y visualmente interpretables: los árboles de decisión, y su extensión mediante ensambles: Random Forest. Se exploran los fundamentos matemáticos de los criterios de división, la poda para controlar el sobreajuste, el concepto de bagging, el error Out-of-Bag (OOB) y la importancia de características. Se incluyen aplicaciones reales, comparativas de métricas y criterios para elegir entre modelos.

1.1. Logro de la sesión

Construir e interpretar árboles de decisión y modelos de ensamble basados en bagging (Random Forest), comprendiendo sus fundamentos matemáticos, sus parámetros clave y las métricas para evaluarlos, y aplicarlos a problemas de clasificación y regresión en contextos diversos.

1.2. Introducción: modelos basados en reglas

Los árboles de decisión son modelos predictivos que representan reglas de decisión en forma de estructura jerárquica [citation:1]. A diferencia de los modelos lineales que suponen una relación paramétrica global, los árboles particionan el espacio de características en regiones más simples donde es más fácil modelar la variable respuesta [citation:4]. Su principal ventaja es la interpretabilidad: cualquier persona puede entender por qué el modelo toma una decisión siguiendo el camino de preguntas binarias [citation:5].

Sin embargo, un único árbol tiende a sobreajustar (alta varianza) y puede ser inestable: pequeños cambios en los datos generan estructuras muy distintas [citation:7]. Para superar estas limitaciones, los métodos de ensamble como Random Forest combinan múltiples árboles, reduciendo la varianza y mejorando la precisión sin sacrificar demasiado la interpretabilidad global [citation:6].

1.3. Árboles de Decisión

1.3.1. Estructura de un árbol

Un árbol de decisión consta de los siguientes elementos [citation:5]:

- **Nodo raíz**: contiene todos los datos de entrenamiento y es el punto donde se realiza la primera división.
- **Nodos internos**: representan puntos de decisión donde se evalúa una característica y se bifurca según el resultado.
- **Ramas**: conectan nodos y representan el resultado de una evaluación (sí/no, o un valor umbral).
- **Nodos hoja (terminales)**: contienen la predicción final (una clase o un valor numérico).
- **Profundidad**: número máximo de divisiones desde la raíz hasta una hoja.

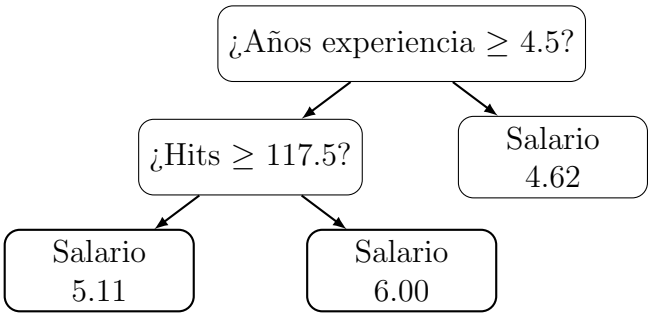

Ejemplo de árbol de regresión para predicción de salario de jugadores de béisbol (en unidades logarítmicas) [citation:4].

1.3.2. Criterios de división

Árboles de clasificación

En cada nodo, se busca la característica y el umbral que maximicen la pureza de los hijos. Las medidas más comunes son:

- **Índice de Gini**: mide la probabilidad de que dos elementos elegidos al azar (con reemplazo) del nodo pertenezcan a clases diferentes [citation:1][citation:7]. Se define como:

$$G = 1 - \sum_{k=1}^{K} p_k^2$$

  donde p_k es la proporción de observaciones de la clase k en el nodo. Valores cercanos a 0 indican pureza máxima (todas las observaciones de una misma clase). El algoritmo CART utiliza Gini por defecto [citation:5].

- **Entropía**: procedente de la teoría de la información, mide el desorden o incertidumbre [citation:1][citation:7]:

$$H = -\sum_{k=1}^{K} p_k \log_2(p_k)$$

La entropía es máxima (1 en binario) cuando hay igual proporción de clases, y mínima (0) cuando el nodo es puro. Se prefiere la entropía cuando se desea crear nodos más balanceados [citation:7].

- **Ganancia de información**: es la reducción de entropía lograda al dividir según una característica [citation:1]:

$$IG(D, a) = H(D) - \sum_{v \in Valores(a)} \frac{|D_v|}{|D|} H(D_v)$$

donde D es el conjunto de datos en el nodo, a es el atributo considerado, y D_v son los subconjuntos tras la división. Se elige el atributo con mayor ganancia de información.

Árboles de regresión

Para variables respuesta continuas, se minimiza la suma de cuadrados de los residuos (RSS) [citation:7]:

$$RSS = \sum_{i \in \text{nodo}} (y_i - \bar{y}_{\text{nodo}})^2$$

Al dividir un nodo en dos regiones R_1 y R_2, se busca minimizar:

$$\sum_{i \in R_1} (y_i - \bar{y}_{R_1})^2 + \sum_{i \in R_2} (y_i - \bar{y}_{R_2})^2$$

La predicción en cada hoja es la media de los valores de entrenamiento que caen en esa región [citation:4].

1.3.3. Ejemplo práctico: cálculo de Gini

Supóngase un nodo con 10 observaciones: 6 de clase A y 4 de clase B.

$$G = 1 - \left(\frac{6}{10}\right)^2 - \left(\frac{4}{10}\right)^2 = 1 - 0.36 - 0.16 = 0.48$$

Si una división propuesta separa en dos hijos:

- Hijo izquierdo: 5 observaciones (5A, 0B) $\rightarrow G_1 = 0$
- Hijo derecho: 5 observaciones (1A, 4B) $\rightarrow G_2 = 1-(1/5)^2-(4/5)^2 = 1-0.04-0.64 = 0.32$

El Gini ponderado de la división es: $\frac{5}{10} \cdot 0 + \frac{5}{10} \cdot 0.32 = 0.16$, menor que 0.48, por lo que la división mejora la pureza.

1.3.4. Proceso de construcción: algoritmo de Hunt

El algoritmo recursivo de construcción sigue estos pasos [citation:5][citation:7]:

1. Comenzar con todos los datos en el nodo raíz.

2. Si todas las observaciones pertenecen a la misma clase (o se cumple un criterio de parada), detenerse y crear un nodo hoja con esa clase (o el valor medio para regresión).
3. En caso contrario, evaluar todas las posibles divisiones para cada característica:
   - Para características numéricas, ordenar los valores y considerar puntos de corte intermedios.
   - Para categóricas, considerar cada categoría como posible rama.
4. Seleccionar la división que maximice la pureza (minimice Gini, entropía o RSS).
5. Dividir los datos en subconjuntos según la regla elegida.
6. Repetir recursivamente para cada subconjunto.

1.3.5. Sobreajuste y poda

Los árboles tienden a crecer hasta que cada hoja contiene observaciones de una sola clase, lo que provoca sobreajuste [citation:4][citation:6]. Para controlarlo:

- **Poda por complejidad-costo (cost-complexity pruning)**: se añade un término de penalización al error:

$$RSS_{\text{podado}} = RSS + \alpha \cdot |T|$$

  donde $|T|$ es el número de nodos hoja y α es un hiperparámetro que controla la penalización. Mayores α producen árboles más pequeños [citation:5].

- **Hiperparámetros de parada**: profundidad máxima, mínimo de muestras por hoja, mínimo de muestras para dividir, etc. Se ajustan mediante validación cruzada.

1.3.6. Ventajas y desventajas de los árboles

1.4. Random Forest

1.4.1. Intuición: combinar múltiples árboles

Random Forest es un método de ensamble basado en bagging (bootstrap aggregating) que construye múltiples árboles de decisión y combina sus predicciones [citation:6]. La idea es que cada árbol individual tiene alta varianza, pero si se promedian muchos árboles no correlacionados, la varianza se reduce drásticamente sin aumentar el sesgo [citation:4].

1.4.2. Bootstrap aggregating (Bagging)

Para cada árbol $b = 1, \ldots, B$:

1. Se toma una muestra bootstrap del conjunto de entrenamiento (muestreo con reemplazo del mismo tamaño que el original). Aproximadamente el 63.2 % de las observaciones originales aparecen al menos una vez en cada muestra [citation:2].
2. Se entrena un árbol de decisión profundo (sin podar) con esa muestra.

Ventajas	**Desventajas**
Fáciles de interpretar y visualizar [citation:5]	Alta varianza: pequeños cambios en datos generan árboles distintos [citation:7]
No requieren estandarización de variables [citation:4]	Propensos al sobreajuste si no se podan [citation:6]
Manejan variables numéricas y categóricas [citation:7]	Pueden ser sesgados si las clases están desbalanceadas [citation:5]
Seleccionan automáticamente características relevantes [citation:4]	En regresión, suelen ser menos precisos que otros modelos [citation:7]
Robustos a outliers [citation:4]	Inestables: la estructura puede cambiar drásticamente con nuevos datos [citation:5]

Cuadro 1.1: Ventajas y desventajas de los árboles de decisión.

3. Para predecir una nueva observación:
   - Clasificación: voto mayoritario de todos los árboles.
   - Regresión: promedio de las predicciones.

1.4.3. Aleatoriedad adicional: selección de características

Random Forest añade una capa extra de aleatoriedad: en cada división de cada árbol, solo se considera un subconjunto aleatorio de características (típicamente $\sqrt{p}$ para clasificación y $p/3$ para regresión, donde p es el número total de predictores) [citation:6]. Esto garantiza que los árboles estén menos correlacionados entre sí, ya que evita que todos elijan las mismas variables fuertes en las primeras divisiones.

1.4.4. Error Out-of-Bag (OOB)

Cada árbol se entrena con una muestra bootstrap. Las observaciones que no forman parte de esa muestra (aproximadamente el 36.8 %) se denominan *out-of-bag* (OOB) [citation:2][citation:8]. Para una observación i, se puede predecir su valor utilizando solo aquellos árboles para los cuales i era OOB. El error OOB se calcula como:

$$\text{Error OOB} = \frac{1}{n}\sum_{i=1}^{n} L(y_i, \hat{y}_i^{\text{OOB}})$$

donde L es la función de pérdida (error cuadrático para regresión, 0-1 para clasificación) y $\hat{y}_i^{\text{OOB}}$ es la predicción agregada solo con árboles donde i era OOB [citation:2].

- **Ventaja**: proporciona una estimación del error de prueba sin necesidad de validación cruzada separada, ya que cada observación nunca es vista por los árboles que la predicen [citation:8].

- **Comparación con validación cruzada**: el error OOB converge al error de validación cruzada leave-one-out a medida que aumenta el número de árboles [citation:2].
- **Precaución**: el error OOB puede sobreestimar el error en muestras balanceadas pequeñas o con predictores débilmente correlacionados [citation:2].

1.4.5. Hiperparámetros principales

- **n_estimators (B)**: número de árboles. A mayor número, más estable es el error. Se busca hasta que el error OOB se estabilice [citation:2].
- **max_features**: número de características consideradas en cada división. Valores típicos: $\sqrt{p}$ (clasificación), $p/3$ (regresión).
- **max_depth**: profundidad máxima de cada árbol. Si es None, los árboles crecen hasta hojas puras.
- **min_samples_split**: mínimo de muestras requeridas para dividir un nodo.
- **min_samples_leaf**: mínimo de muestras en una hoja.
- **bootstrap**: si se usa muestreo bootstrap (True por defecto).

1.4.6. Importancia de características

Random Forest proporciona dos formas de medir la importancia de cada variable [citation:6]:

- **Importancia por impureza (MDI - Mean Decrease in Impurity)**: para cada árbol, se acumula la reducción de impureza (Gini o entropía) aportada por cada variable en todas las divisiones donde aparece. Se promedia sobre todos los árboles. Las variables con mayor reducción total son más importantes.
- **Importancia por permutación (MDA - Mean Decrease in Accuracy)**: para cada variable, se permutan aleatoriamente sus valores en las muestras OOB y se mide cuánto empeora el error. Si al permutar una variable el error aumenta mucho, es señal de que esa variable es relevante.

1.4.7. Ventajas y desventajas de Random Forest

1.5. Comparación de métricas y criterios de selección

1.5.1. Clasificación: precisión, recall, F1 y AUC

En un problema de clasificación con clases desbalanceadas (ej. detección de fraudes, donde los fraudes son ¡1 % del total), la exactitud (accuracy) puede ser engañosa. Por ejemplo, un modelo que siempre predice "no fraude" tendría 99 % de exactitud pero sería inútil. En estos casos, se prioriza:

- **Recall**: minimizar falsos negativos (fraudes no detectados). Un falso negativo puede tener alto costo económico.

Ventajas	**Desventajas**
Menor riesgo de sobreajuste que un solo árbol [citation:6]	Mayor costo computacional (entrenar muchos árboles) [citation:6]
Muy preciso en problemas de clasificación y regresión [citation:4]	Pérdida de interpretabilidad global (aunque se puede medir importancia)
Maneja bien datos de alta dimensionalidad [citation:6]	Puede ser lento en predicción si hay muchos árboles
Proporciona estimación interna del error (OOB) [citation:8]	Requiere más memoria para almacenar el modelo
Robusto a outliers y datos faltantes [citation:4]	No extrapola fuera del rango de entrenamiento [citation:4]
Permite calcular importancia de variables [citation:6]	En regresión, puede tener problemas con datos muy ruidosos

Cuadro 1.2: Ventajas y desventajas de Random Forest.

- **Precisión**: minimizar falsos positivos (alertas falsas). Cada falso positivo requiere revisión manual.
- **F1-score**: media armónica que equilibra ambas cuando no se quiere priorizar una sobre otra.
- **AUC-ROC**: evalúa la capacidad discriminativa global independientemente del umbral.

1.5.2. Regresión: RMSE vs. MAE

Supóngase dos modelos de predicción de precios de viviendas:

- Modelo A: errores [5, 5, 5, 100] (un outlier grande)
- Modelo B: errores [20, 20, 20, 20] (todos moderados)

$\text{MAE}_A = 28.75, MAE_B = 20.SegúnMAE, Besmejor.RMSE_A = \sqrt{(25+25+25+10000)/4} = \sqrt{2518.75} \approx 50.19, \text{RMSE}_B = 20.SegúnRMSE, Besmuchomejor, porquepenalizamáselerrorgrandede$

Conclusión: RMSE es sensible a outliers y se prefiere cuando los errores grandes son especialmente indeseables. MAE es más robusto y se prefiere cuando todos los errores tienen igual importancia [citation:7].

1.5.3. Importancia de la interpretabilidad

- **Árbol único**: cuando se requiere explicar las decisiones a audiencias no técnicas (ej. aprobación de créditos, diagnósticos médicos).
- **Random Forest**: cuando la prioridad es la precisión predictiva, pero aún se desea entender qué variables influyen (mediante importancia).

- **Modelos lineales**: cuando la relación es aproximadamente lineal y se necesita coeficientes interpretables (impacto marginal de cada variable).

1.6. Casos de uso integrados

1.6.1. Detección de fraudes en tarjetas de crédito

Problema: Identificar transacciones fraudulentas en tiempo real. Dataset con cientos de miles de transacciones, clases extremadamente desbalanceadas (¡1 % fraude) [citation:3][citation:6].

Preprocesamiento: Estandarización de montos, creación de variables agregadas por cliente (frecuencia de compras, desviación del gasto), variables temporales (hora, día semana).

Modelado:

- Árbol de decisión único: rápido de entrenar, pero tiende a sobreajustar y tiene bajo recall en la clase minoritaria.
- Random Forest con class_weight='balanced' (asigna mayor peso a la clase minoritaria) o con sobremuestreo SMOTE. El error OOB da una estimación confiable del rendimiento.

Métricas críticas: Recall (minimizar fraudes no detectados) y Precisión (evitar demasiadas alertas falsas). Se puede ajustar el umbral de decisión para equilibrar ambas.

1.6.2. Análisis de riesgo crediticio

Problema: Predecir si un solicitante de préstamo incumplirá el pago [citation:6].

Datos: ingresos, edad, historial crediticio, monto solicitado, etc.

Modelado: Random Forest proporciona importancia de variables, permitiendo identificar qué factores son más determinantes (ej. historial crediticio es el más importante, seguido de ingresos). Los árboles individuales pueden visualizarse para explicar decisiones específicas (ej. por qué se rechazó a un cliente).

Regulación: En entornos regulados (banca), la interpretabilidad es clave. Se pueden extraer reglas de los árboles para justificar las decisiones ante auditores.

1.6.3. Predicción de precios de viviendas (regresión)

Problema: Predecir el precio de venta de viviendas en una ciudad [citation:4].

Datos: área, número de habitaciones, antigüedad, ubicación, calidad de materiales, etc.

Modelado:

- Árbol de regresión: fácil de interpretar, pero puede tener bajo rendimiento predictivo.
- Random Forest Regressor: mejora la precisión, permite calcular importancia de características (ubicación y área suelen ser las más importantes). El error OOB estima el RMSE esperado en nuevos datos.

1.7. Implementación en scikit-learn

1.7.1. Árbol de decisión

```
from sklearn.tree import DecisionTreeClassifier,
   DecisionTreeRegressor, plot_tree
import matplotlib.pyplot as plt

# Clasificaci n
clf = DecisionTreeClassifier(max_depth=5, min_samples_split=10,
   criterion='gini')
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)

# Visualizaci n
plt.figure(figsize=(20,10))
plot_tree(clf, filled=True, feature_names=feature_names,
   class_names=class_names)
plt.show()

# Importancia de caracter sticas
importances = clf.feature_importances_
```

1.7.2. Random Forest

```
from sklearn.ensemble import RandomForestClassifier,
   RandomForestRegressor

# Clasificaci n con error OOB
rf = RandomForestClassifier(n_estimators=100, max_features='sqrt'
   ,
                            oob_score=True, random_state=42)
rf.fit(X_train, y_train)
print(f"OOB Score: {rf.oob_score_}")  # Exactitud en muestras OOB

# Importancia por Gini
importances = rf.feature_importances_

# Importancia por permutaci n (m s fiable)
from sklearn.inspection import permutation_importance
perm_importance = permutation_importance(rf, X_test, y_test,
   n_repeats=10)
```

1.8. Conexión con el resto del curso

Los árboles y Random Forest introducen conceptos fundamentales que se extienden a otros modelos:

- **Ensambles**: Random Forest es un ejemplo de bagging. En sesiones posteriores se verá boosting (Gradient Boosting, XGBoost), que construye árboles secuencialmente.
- **Importancia de características**: técnica utilizada también en modelos lineales regularizados y en análisis exploratorio.
- **Manejo de no linealidades**: los árboles capturan interacciones complejas de forma natural, algo que los modelos lineales no pueden sin ingeniería manual.
- **Validación interna**: el error OOB es una alternativa eficiente a la validación cruzada, aplicable también en otros métodos basados en bagging.

1.9. Resumen

- Los árboles de decisión son modelos interpretables que particionan el espacio de características mediante reglas binarias. Utilizan criterios como Gini, entropía o RSS para seleccionar las mejores divisiones.
- Su principal limitación es la alta varianza y tendencia al sobreajuste, controlable mediante poda o hiperparámetros.
- Random Forest combina múltiples árboles entrenados con muestras bootstrap y aleatoriedad en las características, reduciendo la varianza y mejorando la precisión.
- El error OOB proporciona una estimación interna del rendimiento sin necesidad de validación cruzada.
- La importancia de características (por impureza o permutación) permite interpretar qué variables son más relevantes.
- La elección entre árbol único y Random Forest depende del equilibrio entre interpretabilidad y precisión, así como del contexto del problema.