Sesión 13

Interpretabilidad de Modelos: Explicando las decisiones de la caja negra

Carlos César Sánchez Coronel

MACHINE LEARNING

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

La necesidad de explicaciones

- Modelos complejos (XGBoost, redes neuronales) son "cajas negras".
- En ámbitos críticos (salud, finanzas, justicia) la transparencia es obligatoria.
- Regulaciones como el GDPR otorgan el "derecho a una explicación".
- La interpretabilidad también ayuda a:
  - Depurar modelos (detectar sesgos, errores).
  - Generar confianza en usuarios y stakeholders.
  - Descubrir nuevo conocimiento.

Tipos de interpretabilidad

Interpretabilidad global

- Comportamiento promedio del modelo.
- ¿Qué variables son más importantes en general?
- ¿Cómo afectan en promedio?

Interpretabilidad local

- Explicación de una predicción individual.
- ¿Por qué este cliente fue rechazado?
- Necesario para dar explicaciones personalizadas.

Métodos

- **Intrínsecos**: el modelo es interpretable por sí mismo (regresión lineal, árboles pequeños).
- **Post-hoc**: se aplican después de entrenar (SHAP, LIME, PDP).

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Importancia por impureza (MDI)

Definición

En árboles y Random Forest, la importancia de una característica se calcula sumando la reducción de impureza (Gini o entropía) en todos los nodos donde aparece, ponderada por la proporción de muestras.

$$\text{Imp}(j) = \frac{\sum_{t \in T} \Delta i(t) \cdot n(t)}{\sum_{t \in T} n(t)}$$

- **Ventaja**: rápida, incluida en la mayoría de librerías.
- **Limitaciones**: sesgo hacia variables numéricas o con muchas categorías; no indica dirección del efecto; puede ser engañosa con correlaciones.

Importancia por permutación

Idea

Si una variable es importante, permutar sus valores rompe la relación con la variable objetivo, aumentando el error.

$$\text{Imp}(j) = \frac{1}{K} \sum_{k=1}^{K} (\text{error}_{\text{perm}} - \text{error}_{\text{original}})$$

- Más fiable que MDI, modelo-agnóstico, independiente de la escala.
- Método recomendado en scikit-learn.

Importancia por permutación en Python

```
from sklearn.inspection import permutation_importance
from sklearn.ensemble import RandomForestClassifier

model = RandomForestClassifier().fit(X_train, y_train)
result = permutation_importance(model, X_test, y_test, n_repeats=10)
sorted_idx = result.importances_mean.argsort()
```

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Partial Dependence Plot (PDP)

Definición

Muestra cómo cambia la predicción promedio al variar una (o dos) características, marginalizando sobre el resto.

$$\widehat{f}_{x_s}(x_s) = \frac{1}{n}\sum_{i=1}^{n} f(x_s, x_c^{(i)})$$

- **Interpretación**: relación monótona, lineal, o compleja.
- **Limitación**: asume independencia entre x_s y x_c; puede promediar regiones irreales si hay correlación.

Individual Conditional Expectation (ICE)

Idea

Para cada instancia, se mantienen fijas sus otras variables y se varía x_s, obteniendo una curva por observación.

- El PDP es el promedio de todas las curvas ICE.
- Si las curvas ICE no son paralelas, hay interacciones.
- Útil para detectar heterogeneidad en el efecto de una variable.

PDP e ICE con scikit-learn

```
from sklearn.inspection import PartialDependenceDisplay

# PDP
PartialDependenceDisplay.from_estimator(model, X_train,
    features=['duration', 'amount'], kind='average')

# ICE
PartialDependenceDisplay.from_estimator(model, X_train,
    features=['duration'], kind='individual')
```

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Valores de Shapley en teoría de juegos

Fórmula general

$$\phi_j = \sum_{S \subseteq P \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)]$$

donde $v(S)$ es la predicción usando solo las características en S.

- Asigna a cada característica su contribución justa a la predicción.
- Propiedades deseables: eficiencia, simetría, linealidad, dummy.

SHAP en la práctica

- **Kernel SHAP**: modelo-agnóstico, combina LIME con propiedades Shapley (lento).
- **Tree SHAP**: específico para árboles, rápido y exacto (aprovecha la estructura de los árboles).
- **Deep SHAP**: para redes neuronales.

Interpretación

- Valor base (expected value): predicción media en el conjunto de entrenamiento.
- SHAP values: contribuciones de cada característica.
- Suma: valor base $+ \sum \phi_j =$ predicción (propiedad de eficiencia).

Visualizaciones SHAP

- **Summary plot**: importancia global + dirección del efecto.
- **Dependence plot**: relación entre el valor de la variable y su impacto SHAP; puede colorearse por otra variable para detectar interacciones.
- **Force plot / Waterfall plot**: explicación local para una instancia.

TreeExplainer en Python

```python
import shap

explainer = shap.TreeExplainer(model)
shap_values = explainer.shap_values(X_test)

# Summary plot
shap.summary_plot(shap_values, X_test, feature_names=feature_names)

# Force plot para una instancia
shap.force_plot(explainer.expected_value, shap_values[0,:],
                X_test.iloc[0,:])
```

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

LIME: idea fundamental

Pasos

1. Generar muestras aleatorias alrededor de la instancia a explicar.
2. Obtener predicciones del modelo original para esas muestras.
3. Ponderar las muestras según su proximidad (kernel exponencial).
4. Ajustar un modelo interpretable (lineal) en esa vecindad.
5. Los coeficientes del modelo simple son la explicación.

Ventajas y limitaciones de LIME

- **Ventajas**: agnóstico al modelo, rápido, intuitivo.
- **Limitaciones**: inestable (depende del muestreo aleatorio), difícil definir la vecindad.

LIME en Python

```
from lime.lime_tabular import LimeTabularExplainer

explainer = LimeTabularExplainer(X_train.values,
                                 feature_names=feature_names,
                                 class_names=['bueno', 'malo'],
                                 mode='classification')
exp = explainer.explain_instance(X_test.iloc[0].values,
                                 model.predict_proba)
exp.show_in_notebook()
```

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Comparación: SHAP vs LIME vs PDP vs Importancia

Método	**Ámbito**	**Modelo-agnóstico**	**Velocidad**
Importancia (permutación)	Global	Sí	Rápida
PDP	Global	Sí	Media
ICE	Local/Global	Sí	Media
SHAP (Tree)	Local/Global	No	Rápida
SHAP (Kernel)	Local/Global	Sí	Lenta
LIME	Local	Sí	Media

¿Cuándo usar cada uno?

- **Importancia por permutación**: ranking global rápido y fiable.
- **PDP/ICE**: entender la relación funcional de una variable.
- **SHAP**: explicaciones locales consistentes + resumen global (estándar de facto).
- **LIME**: alternativa rápida cuando no se puede usar SHAP, o para modelos no árbol.

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Finanzas: scoring crediticio

- Cliente rechazado exige explicación (GDPR).
- Usar SHAP force plot para mostrar contribuciones.
- Generar informe en lenguaje natural con los factores principales.

Salud: diagnóstico asistido

- Médico necesita entender por qué el modelo predice alto riesgo de diabetes.
- PDP de glucosa, IMC, edad muestra efectos.
- SHAP local para un paciente específico.

Recursos humanos: detección de sesgos

- Analizar valores SHAP por grupo demográfico.
- Calcular métricas de equidad (disparate impact, igualdad de oportunidades).
- Identificar variables proxy.

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Datos y modelo

- Dataset German Credit (UCI): 1000 solicitudes, 20 variables, objetivo binario (bueno/malo).
- Modelo: XGBoost con AUC 0.78.
- Variables clave: duration, amount, age, purpose, other$_installment_plans$.

Interpretabilidad global

- Importancia por permutación: duration, amount, age.
- PDP de duration: la probabilidad de malo aumenta con la duración.
- SHAP summary plot: valores altos de duration y amount contribuyen al riesgo (SHAP positivo); age joven también.

Explicación local (cliente rechazado)

Datos del cliente

- duration = 48 meses
- amount = 5000 €
- age = 25 años
- purpose = coche
- other$_{i}nstallment_{p}lans = yes$

Predicción: 0.82 (riesgo alto).

SHAP force plot (simulado)

- Valor base: 0.35
- duration=48: +0.25
- amount=5000: +0.15
- age=25: +0.10
- other$_{i}nstallment_{p}lans = yes$: +0,07

Comunicación al cliente

"Su solicitud fue rechazada principalmente porque la duración del crédito (48 meses) es superior a la media, lo que incrementa el riesgo. También influyen el monto solicitado (5000 €), su edad (25 años) y el hecho de tener otros planes de pago. Estos factores combinados resultan en una alta probabilidad de incumplimiento."

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Limitaciones de los métodos

- **SHAP**: con correlaciones extremas, las contribuciones pueden repartirse de manera inestable; no implica causalidad.
- **LIME**: inestable por muestreo; ejecutar varias veces para verificar consistencia.
- **PDP**: puede promediar regiones irreales si hay correlaciones (usar ALE plots).
- **Importancia**: no indica dirección del efecto.

Buenas prácticas

- Validar explicaciones con expertos del dominio.
- No confundir correlación con causalidad.
- Usar múltiples métodos para obtener una visión completa.
- Para cumplimiento regulatorio, documentar el proceso de interpretabilidad.

Contenido

1. Introducción
2. Importancia de Características en Árboles
3. PDP e ICE
4. SHAP
5. LIME
6. Comparación de Métodos
7. Aplicaciones en la Industria
8. Caso Integrado: German Credit
9. Limitaciones y Buenas Prácticas
10. Conexión y Resumen

Conexión con el resto del curso

- Importancia de características se basa en métricas de sesiones anteriores.
- SHAP utiliza teoría de juegos (matemáticas discretas).
- LIME usa regresión lineal local (modelos lineales).
- Interpretabilidad es clave para MLOps y gobernanza de modelos (sesión 14).

Lo que hemos aprendido

Conceptos clave

- Interpretabilidad global vs local.
- Importancia por permutación (robusta) vs MDI (sesgada).
- PDP e ICE para relaciones parciales.
- SHAP: valores de Shapley, TreeExplainer, visualizaciones.
- LIME: explicaciones locales rápidas.
- Aplicaciones en finanzas, salud, detección de sesgos.
- Caso práctico: German Credit.

¡Gracias!