Sesión 1

Introducción al Machine Learning

Carlos César Sánchez Coronel

MACHINE LEARNING

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Inteligencia Artificial vs Machine Learning vs Deep Learning

Jerarquía de conceptos

- **Inteligencia Artificial (IA):** Campo amplio que busca crear sistemas con capacidades humanas (razonamiento, percepción, aprendizaje).
- **Machine Learning (ML):** Subcampo de la IA; algoritmos que aprenden de datos sin programación explícita.
- **Deep Learning (DL):** Subcampo del ML que usa redes neuronales profundas para modelar patrones complejos.

$$\text{IA} \supset \text{ML} \supset \text{DL}$$

Tipos de Aprendizaje

Supervisado

Datos etiquetados.
Regresión: valor continuo (precio).
Clasificación: categoría (spam/no spam).

Por refuerzo

Agente interactúa con entorno.
Recompensas, maximización acumulada.
Ej: robot aprendiendo a caminar.

No supervisado

Sin etiquetas.
Clustering: agrupar clientes.
Reducción dimensionalidad: PCA.

Semi-supervisado / Autosupervisado

Combinan datos etiquetados y no etiquetados.
Ej: predecir la siguiente palabra (NLP).

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Estructuras de datos en IA

Escalares, Vectores, Matrices y Tensores

- **Escalar:** número real (bias, temperatura). Ej: $x = 5{,}2$
- **Vector:** lista ordenada (punto en espacio de características). Ej: $\mathbf{x} = [2{,}5, 1{,}8, 3{,}0]$
- **Matriz:** tabla 2D (imagen en escala de grises). Ej: $\mathbf{X} \in \mathbb{R}^{n \times m}$
- **Tensor:** generalización a más dimensiones (lote de imágenes a color). Ej: $\mathcal{T} \in \mathbb{R}^{B \times H \times W \times C}$

Funciones en IA

- **Lineales:** $f(x) = mx + b$ (regresión)
- **Polinomiales:** $f(x) = a_n x^n + \ldots$ (aproximación)
- **Exponenciales:** e^x (softmax, pérdida)
- **Logarítmicas:** $\ln x$ (entropía)
- **Trigonométricas:** sin, cos (positional encodings)

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Funciones de activación (I)

Introducen no linealidad.

Sigmoide

$\sigma(x) = \frac{1}{1+e^{-x}} \in (0,1)$

ReLU

$\text{máx}(0, x)$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

Tanh

$\tanh(x) \in (-1, 1)$

Leaky ReLU

$\text{máx}(\alpha x, x)$

Funciones de activación (II)

Softmax

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

Convierte logits en distribución de probabilidad.

GELU / Swish

GELU: $x\,\Phi(x)$ (usada en transformers).
Swish: $x \cdot \sigma(x)$ (EfficientNet).

Funciones de pérdida

Regresión

- MSE: $\frac{1}{n}\sum(y_i - \hat{y}_i)^2$
- MAE: $\frac{1}{n}\sum|y_i - \hat{y}_i|$

Clasificación

- Log-loss: $-\sum[y_i \log \hat{y}_i + (1 - y_i)\log(1 - \hat{y}_i)]$
- Hinge loss: $\text{máx}(0, 1 - y_i\hat{y}_i)$
- Focal loss (clases desbalanceadas)

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Lógica proposicional en IA

Aplicaciones

- **Árboles de decisión:** nodos con condiciones lógicas.
- **Sistemas basados en reglas:** motores de inferencia.
- **Programación lógica** (Prolog).
- **Verificación de modelos** en sistemas críticos.

Notación de sumatorias y productorias

Sumatoria

$$\sum_{i=1}^{n} x_i = x_1 + x_2 + \cdots + x_n$$

Ej: $z = \sum_{i=1}^{n} w_i x_i + b$

Productoria

$$\prod_{i=1}^{n} x_i = x_1 \cdot x_2 \cdots x_n$$

Ej: $P(X_1, \ldots, X_n) = \prod P(X_i)$

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Librerías esenciales

Fundamentales

NumPy, SciPy, Matplotlib, SymPy

Deep Learning

TensorFlow/Keras, PyTorch, JAX

Machine Learning clásico

Scikit-learn, XGBoost, LightGBM, CatBoost

Especializadas

NLP: HuggingFace, NLTK, spaCy
Visión: OpenCV, torchvision
Audio: librosa
Grafos: NetworkX, PyG

Ejemplo práctico en Python

```
import numpy as np
import matplotlib.pyplot as plt

def sigmoid(x): return 1/(1+np.exp(-x))
x = np.linspace(-5,5,100)
plt.plot(x, sigmoid(x))
plt.title('Funci n Sigmoide')
plt.grid(True)
plt.show()
```

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Regresión Lineal

Formulación

$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon$

Función de coste (MSE)

$J(\beta) = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$

- Solución analítica: $\hat{\beta} = (X^T X)^{-1} X^T y$ (coste $O(p^3)$)
- Gradiente descendente: $\nabla J = \frac{2}{n} X^T (X\beta - y)$
- **Supuestos:** linealidad, homocedasticidad, normalidad (para inferencia)

Regresión Logística

Modelo de clasificación binaria

$P(y = 1|x) = \sigma(\beta^T x) = \frac{1}{1+e^{-\beta^T x}}$

Log-loss (entropía cruzada)

$J(\beta) = -\sum[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$

- Gradiente: $\nabla J = \sum(\hat{y}_i - y_i)x_i$
- No tiene solución cerrada; se optimiza con gradiente descendente.

k-Vecinos más cercanos (k-NN)

Funcionamiento

Clasifica un nuevo punto por voto mayoritario de sus k vecinos más cercanos (según distancia euclidiana, Manhattan, etc.)

- Entrenamiento: $O(1)$ (solo almacena)
- Inferencia: $O(n \cdot p)$ (costoso con millones de datos)
- Elección de k: validación cruzada.
- k pequeño $\rightarrow$ sobreajuste; k grande $\rightarrow$ subajuste.

Naive Bayes

Teorema de Bayes

$P(C_k|x) \propto P(C_k) \prod_{j=1}^{n} P(x_j|C_k)$

- Supuesto de independencia condicional ("naive").
- Para características continuas: $P(x_j|C_k) \sim \mathcal{N}(\mu_{kj}, \sigma_{kj}^2)$
- Muy eficiente en problemas de texto (clasificación de documentos).

Máquinas de Vectores de Soporte (SVM)

Idea principal

Maximizar el margen entre clases mediante un hiperplano óptimo.

- **Vectores de soporte:** puntos que definen el margen.
- **Truco del kernel:** transformación implícita a mayor dimensión (lineal, RBF, polinomial).
- Parámetro C: controla penalización por errores.

Árboles de Decisión

Partición recursiva

Cada nodo interno pregunta sobre una característica, maximizando la pureza de los hijos.

Índice de Gini: $1 - \sum p_k^2$

Entropía: $-\sum p_k \log p_k$

- Interpretables, pero tienden a sobreajustar.
- Mitigación: poda, profundidad máxima, mínimo de muestras por hoja.

Random Forest

Ensemble de árboles

Construye múltiples árboles con muestras bootstrap (bagging) y aleatoriedad en características.

- Reduce la varianza sin aumentar el sesgo.
- Predicción por promedio (regresión) o voto mayoritario (clasificación).
- Robusto y de buen rendimiento en problemas tabulares.

Redes Neuronales (MLP)

Arquitectura

Capas de neuronas: entrada, ocultas, salida. Cada neurona: $a = \sigma(\sum w_j x_j + b)$.

- **Backpropagation:** gradientes por regla de la cadena.
- Activaciones no lineales esenciales para aproximar funciones complejas.

K-Means

Objetivo

Particionar datos en k clusters minimizando la suma de distancias cuadráticas intra-cluster:
$J = \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2$

- Algoritmo iterativo: asignación y actualización de centroides.
- Elección de k: método del codo, silhouette score.

PCA (Análisis de Componentes Principales)

Reducción de dimensionalidad

Proyecta datos a un nuevo espacio de menor dimensión conservando la máxima varianza.

- Componentes principales = autovectores de la matriz de covarianza.
- Se conservan los primeros k componentes que explican un porcentaje de varianza (ej. 95 %).

DBSCAN

Clustering basado en densidad

Agrupa puntos que están estrechamente empaquetados, marcando como ruido los puntos aislados.

- **Puntos núcleo, borde y ruido.**
- Detecta clusters de forma arbitraria y outliers.
- Parámetros: `eps` (radio) y `minPts`.

Conceptos básicos de RL

Elementos

Agente, entorno, estado, acción, recompensa.

- Objetivo: maximizar recompensa acumulada $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$.
- **Ecuación de Bellman:** $Q(s,a) = r + \gamma \operatorname{máx}_{a'} Q(s',a')$.
- **Q-learning:** $Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \operatorname{máx}_{a'} Q(s',a') - Q(s,a)]$.
- **Exploración vs explotación** (ej. ϵ-greedy).

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Métricas de evaluación

Clasificación

- Accuracy, precisión, recall, F1, AUC-ROC
- Precisión $= \frac{VP}{VP+FP}$
- Recall $= \frac{VP}{VP+FN}$

Regresión

- MSE, MAE, RMSE, R^2

Validación cruzada

Divide los datos en k pliegues; más robusta que una única partición.

Metodología CRISP-DM

Fases

1. Comprensión del negocio
2. Comprensión de los datos
3. Preparación de los datos
4. Modelado
5. Evaluación
6. Despliegue

- Proceso iterativo, no lineal.
- Aplicado a predicción de precios de viviendas (Pregunta 19).

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Diseño de un sistema de recomendación (Netflix)

Combinación de aprendizajes (Pregunta 20)

- **Supervisado:** predecir rating o probabilidad de ver.
- **No supervisado:** segmentar usuarios (clustering).
- **Refuerzo contextual:** optimizar recomendaciones secuenciales (bandits).

Métricas offline: Precision@k, Recall@k, NDCG.

Métricas online: A/B test (tiempo de visualización, retención).

Cold start: para nuevos usuarios o contenido: popularidad, metadatos.

Contenido

1. Introducción y Tipos de Aprendizaje
2. Fundamentos Matemáticos
3. Funciones de Activación y Pérdida
4. Lógica y Notación
5. Herramientas de Python
6. Modelos de Machine Learning
   - Supervisados
   - No Supervisados
   - Aprendizaje por Refuerzo
7. Evaluación y Metodología
8. Caso integrador: Sistema de Recomendación
9. Conclusión

Resumen de la sesión

Lo que hemos visto

- Jerarquía IA $\supset$ ML $\supset$ DL y tipos de aprendizaje.
- Fundamentos matemáticos: vectores, matrices, funciones.
- Funciones de activación y pérdida.
- Herramientas de Python (NumPy, PyTorch, etc.).
- Modelos supervisados, no supervisados y por refuerzo.
- Evaluación y metodología CRISP-DM.
- Caso integrador de recomendación.

¡Gracias!