Sesión 3

Regresión Lineal y Regularización

Carlos César Sánchez Coronel

MACHINE LEARNING

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Regresión Lineal Simple

Formulación

$y = \beta_0 + \beta_1 x + \varepsilon$

- β_0: intersección
- β_1: pendiente
- ε: error

Estimación MCO

$$\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- **Interpretación:** $\hat{\beta}_1$ es el cambio esperado en y por unidad de x.
- **Caso de uso:** Relación entre años de experiencia y salario.

Regresión Lineal Múltiple

Formulación matricial

$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

- $\mathbf{y}$: $n \times 1$, $\mathbf{X}$: $n \times (p+1)$, $\boldsymbol{\beta}$: $(p+1) \times 1$, $\boldsymbol{\varepsilon}$: $n \times 1$

Solución MCO

$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$

- Requiere que $\mathbf{X}^T\mathbf{X}$ sea invertible (no multicolinealidad perfecta).

- **Interpretación ceteris paribus:** β_j mide el efecto de x_j manteniendo las demás constantes.
- **Caso de uso:** Predicción de precios de viviendas (área, habitaciones, antigüedad, ubicación).

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Supuestos de la Regresión Lineal

Linealidad

Relación lineal entre predictores y respuesta.
Detección: gráfico de residuos vs. ajustados.

Homocedasticidad

Varianza constante de los errores.
Detección: patrón de embudo en residuos vs. ajustados.

Independencia

Errores no correlacionados.
Detección: gráfico de residuos vs. orden.

Normalidad

Errores normal (para inferencia).
Detección: Q-Q plot, histograma.

- Para predicción, la normalidad es menos crítica.
- La violación de homocedasticidad afecta intervalos de confianza.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Métricas de Error en Regresión

MSE (Error Cuadrático Medio)

$$\frac{1}{n}\sum(y_i - \hat{y}_i)^2$$

MAE (Error Absoluto Medio)

$$\frac{1}{n}\sum|y_i - \hat{y}_i|$$

RMSE (Raíz del MSE)

$$\sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}$$

R^2 (Coeficiente de Determinación)

$$1 - \frac{RSS}{TSS}$$

Ejemplo: errores = [10,10,10,100]

MAE = 32.5, RMSE 50.7

- RMSE penaliza más los errores grandes.

Cuándo usar cada métrica

- **RMSE:** Cuando los errores grandes son críticos (ej. rotura de stock).
- **MAE:** Robustez a outliers, todos los errores igual de importantes.
- **MSE:** Útil como función de pérdida (diferenciable).
- R^2**:** Bondad de ajuste, pero no sirve para comparar modelos con diferente número de predictores (usar R^2 ajustado).

R^2 ajustado

$R^2_{\text{adj}} = 1 - \dfrac{RSS/(n-p-1)}{TSS/(n-1)}$ penaliza la inclusión de variables irrelevantes.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

El problema del sobreajuste

Alta varianza

Modelo demasiado complejo, se ajusta al ruido.

- Buen rendimiento en entrenamiento, malo en prueba.

Alto sesgo

Modelo demasiado simple, no captura la señal.

- Mal rendimiento en ambos conjuntos.

Trade-off sesgo-varianza

La regularización aumenta ligeramente el sesgo para reducir drásticamente la varianza, mejorando la generalización.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Regularización Ridge

Función de coste

$$J_{\text{ridge}}(\boldsymbol{\beta}) = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

- $\lambda \geq 0$ controla la fuerza de regularización.
- Solución analítica: $\hat{\boldsymbol{\beta}}_{\text{ridge}} = (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^T\mathbf{y}$
- **Efecto:** encoge los coeficientes hacia cero, pero ninguno se anula exactamente.

Caso de uso

Muchas variables correlacionadas (ej. marketing con variables demográficas y de consumo). Ridge estabiliza las estimaciones.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Regularización Lasso

Función de coste

$$J_{\text{lasso}}(\boldsymbol{\beta}) = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{p} |\beta_j|$$

- La penalización L1 puede forzar algunos coeficientes exactamente a cero.
- **Selección automática de variables:** produce modelos dispersos e interpretables.
- No tiene solución analítica cerrada (se usa descenso por coordenadas).

Caso de uso

Identificar factores clave en un proceso industrial con cientos de sensores.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Elastic Net: combinación de L1 y L2

Función de coste

$$J_{\text{elastic}}(\boldsymbol{\beta}) = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \left(\alpha \sum_{j=1}^{p} |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^{p} \beta_j^2 \right)$$

- $\alpha \in [0, 1]$ controla la mezcla: $\alpha = 0 \rightarrow$ Ridge, $\alpha = 1 \rightarrow$ Lasso.
- **Ventajas:** selecciona grupos de variables correlacionadas, maneja $p > n$.

Caso de uso

Análisis de expresión génica (miles de genes, pocas muestras). Elastic Net identifica grupos de genes relacionados con una enfermedad.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Validación cruzada para elegir λ y α

Proceso

1. Dividir datos en k folds.
2. Para cada combinación de λ (y α), entrenar en $k-1$ folds y evaluar en el fold restante.
3. Promediar el error de validación.
4. Elegir el valor que minimiza el error.

Métrica recomendada

RMSE o MAE según el contexto.

- **Curva de regularización:** muestra cómo varían los coeficientes con λ.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Comparación: Ridge vs Lasso vs Elastic Net

Característica	**Ridge (L2)**	**Lasso (L1)**	**Elastic Net**
Selección de variables	No	Sí (individual)	Sí (grupos)
Manejo de multicolinealidad	Excelente	Regular	Bueno
Estabilidad	Alta	Puede ser inestable	Buena
Interpretabilidad	Media	Alta	Alta

- **Uso típico:** Ridge para variables correlacionadas, Lasso para modelos parsimoniosos, Elastic Net como compromiso.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Predicción de precios de viviendas (Ames, Kaggle)

Datos

80 variables predictoras (área, habitaciones, año, ubicación, calidad...).

Preprocesamiento

- Imputación de nulos (mediana, moda).
- Codificación one-hot (200 features).
- Estandarización (necesaria para regularización).

Modelado

- MCO (sin regularización)
- Ridge (validación cruzada)
- Lasso (validación cruzada)
- Elastic Net (búsqueda de λ, α)

Resultados esperados

MCO sobreajusta; Ridge estabiliza; Lasso selecciona 20-30 variables clave; Elastic Net balancea.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Diseño de un sistema de valoración automática

Requisitos

- 500,000 registros, 100 variables.
- Alta precisión e interpretabilidad.
- Variables correlacionadas.

Pipeline

- Imputación robusta.
- Log/Box-Cox para asimetría.
- Target encoding para ubicación.
- Interacciones (área$\times$calidad).
- Estandarización.

- Validación cruzada con RMSE.
- Monitoreo en producción: PSI, drift.
- Automatización MLOps.

Modelo elegido: Elastic Net

- Selecciona variables (interpretabilidad).
- Maneja correlaciones.
- Estable.

Contenido

1. Regresión Lineal Simple y Múltiple
2. Supuestos del Modelo
3. Métricas de Evaluación
4. Sobreajuste y Regularización
5. Ridge (L2)
6. Lasso (L1)
7. Elastic Net
8. Selección de Hiperparámetros
9. Comparación de Métodos
10. Caso de Estudio Integrado
11. Caso Avanzado: Fintech Hipotecaria
12. Resumen y Conexión

Lo que hemos aprendido

Conceptos clave

- Regresión lineal: formulación, estimación, interpretación.
- Supuestos y métricas de evaluación.
- Sobreajuste y trade-off sesgo-varianza.
- Regularización: Ridge (L2), Lasso (L1), Elastic Net.
- Selección de hiperparámetros con validación cruzada.
- Aplicación a casos reales (viviendas, fintech, bioinformática).

Conexión con el resto del curso

Estos conceptos se extienden a:

- Regresión logística regularizada.
- Redes neuronales (weight decay).
- Selección de características en modelos complejos.

¡Gracias!