Temario Completo: Modelos de Clasificación

Desde el balanceo de clases hasta la producción

9 de marzo de 2026

Resumen

Este documento presenta un temario exhaustivo para el desarrollo de modelos de clasificación, cubriendo desde la preparación específica post-EDA hasta la implementación en producción. Incluye técnicas para datos desbalanceados, múltiples métricas de evaluación, calibración de probabilidades, interpretabilidad y consideraciones prácticas para casos reales de clasificación binaria y multiclase.

Índice

1. Preparación Específica para Clasificación **3**
1.1. Análisis de la Variable Objetivo . . . 3
1.2. Análisis de Separabilidad . . . 3
1.3. Transformaciones Específicas . . . 3

2. Tipos de Modelos de Clasificación **4**
2.1. Modelos Lineales y Probabilísticos . . . 4
2.2. Modelos Basados en Fronteras y Árboles . . . 4
2.3. Modelos Avanzados y No Convencionales . . . 5

3. Manejo de Datos Desbalanceados **5**
3.1. Detección y Diagnóstico . . . 5
3.2. Técnicas de Muestreo . . . 5
3.3. Técnicas a Nivel de Algoritmo . . . 6
3.4. Evaluación con Datos Desbalanceados . . . 6

4. Métricas y Evaluación **7**
4.1. Métricas para Clasificación Binaria . . . 7
4.2. Métricas para Clasificación Multiclase . . . 7
4.3. Curvas de Evaluación . . . 7
4.4. Validación Cruzada Específica . . . 8

5. Calibración de Probabilidades **8**
5.1. Importancia de Probabilidades Bien Calibradas . . . 8
5.2. Métodos de Calibración . . . 8

6. Selección de Modelos y Optimización **9**
6.1. Búsqueda de Hiperparámetros Específicos . . . 9
6.2. Comparación de Modelos . . . 9

7. Interpretabilidad y Explicabilidad **10**
7.1. Importancia de Variables en Clasificación . . . 10
7.2. Métodos Globales . . . 10
7.3. Métodos Locales . . . 10
7.4. Interpretación Específica por Modelo . . . 11

8. Problemas Comunes y Soluciones **11**
8.1. Overfitting en Clasificación . . . 11
8.2. Underfitting . . . 11
8.3. Clases Superpuestas . . . 12
8.4. Inestabilidad de Modelos . . . 12

9. Técnicas Avanzadas **12**
9.1. Clasificación Multiclase y Multi-etiqueta . . . 12
9.2. Clasificación con Datos Secuenciales . . . 12
9.3. Learning to Rank . . . 13
9.4. Active Learning para Clasificación . . . 13

10. Producción y Mantenimiento **13**
10.1. Despliegue de Clasificadores . . . 13
10.2. Monitoreo en Producción . . . 13
10.3. Mantenimiento y Actualización . . . 14

11. Checklist de Implementación **14**

12. Casos de Uso Comunes y Consideraciones **15**
12.1. Clasificación Binaria Típica . . . 15
12.2. Clasificación Multiclase . . . 15
12.3. Detección de Anomalías . . . 15
12.4. Clasificación con Restricciones . . . 15

13. Conclusiones y Buenas Prácticas **16**

1 Preparación Específica para Clasificación

1.1 Análisis de la Variable Objetivo

- **Caracterización del problema:**
  - Clasificación binaria vs multiclase vs multi-etiqueta
  - Número de clases y su distribución
  - Balanceo de clases: frecuencia y proporción
  - Identificación de clase minoritaria y mayoritaria
- **Visualizaciones específicas:**
  - Gráfico de barras de frecuencias por clase
  - Diagrama de sectores para proporciones
  - Matriz de confusión de la línea base
- **Métricas de desbalanceo:**
  - Índice de desbalance: $\frac{\text{clase mayoritaria}}{\text{clase minoritaria}}$
  - Entropía de las clases
  - Coeficiente de Gini para distribución

1.2 Análisis de Separabilidad

- **Técnicas de visualización:**
  - Pairplot coloreado por clase
  - PCA/t-SNE/UMAP para visualización 2D/3D
  - Parallel coordinates plot
- **Métricas de separabilidad:**
  - Fisher's Discriminant Ratio
  - Separabilidad de clases por feature
  - Matriz de distancias entre clases (Mahalanobis)

1.3 Transformaciones Específicas

- **Features discriminantes:**
  - Ratios entre variables que separan clases
  - Interacciones específicas por clase
  - Umbrales óptimos (búsqueda de puntos de corte)
- **Preparación para modelos probabilísticos:**
  - Calibración de features
  - Transformaciones que mejoren separabilidad
  - Creación de variables dicotómicas intermedias

2 Tipos de Modelos de Clasificación

2.1 Modelos Lineales y Probabilísticos

- **Regresión Logística:**
  - Binaria: $P(y = 1|x) = \frac{1}{1+e^{-(\beta_0+\beta_1 x_1+\ldots)}}$
  - Multinomial (softmax): $P(y = k|x) = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}$
  - Interpretación directa de coeficientes (odds ratios)
  - Regularización L1, L2, Elastic Net
- **Análisis Discriminante:**
  - LDA (Linear Discriminant Analysis): asume covarianzas iguales
  - QDA (Quadratic Discriminant Analysis): covarianzas diferentes
  - Asume normalidad multivariante
- **Naive Bayes:**
  - GaussianNB (variables continuas)
  - MultinomialNB (conteos/frecuencias)
  - BernoulliNB (variables binarias)
  - Asume independencia condicional

2.2 Modelos Basados en Fronteras y Árboles

- **Máquinas de Soporte Vectorial (SVM):**
  - Maximización del margen
  - Kernel trick: lineal, polinomial, RBF, sigmoide
  - Parámetro C (trade-off margen vs error)
  - SVM para clasificación multiclase (one-vs-one, one-vs-rest)
- **Árboles de Decisión:**
  - Criterios de división: Gini, entropía, error de clasificación
  - Poda para evitar overfitting
  - Profundidad máxima, muestras mínimas por hoja
  - Fácil interpretación pero inestables
- **Random Forest Classifier:**
  - Bagging + aleatoriedad en features
  - Maneja desbalanceo con class_weight
  - Importancia de variables por impurity decrease
  - Out-of-bag (OOB) error como validación interna
- **Gradient Boosting para Clasificación:**
  - XGBoost, LightGBM, CatBoost
  - Función objetivo: log-loss, exponencial
  - Manejo nativo de categoricals (CatBoost, LightGBM)
  - Early stopping para evitar overfitting

2.3 Modelos Avanzados y No Convencionales

- **K-Vecinos Más Cercanos (KNN):**
  - Clasificación por mayoría de votos
  - Sensible a escala y dimensionalidad
  - Selección de k óptimo
- **Redes Neuronales para Clasificación:**
  - MLP con softmax en capa de salida
  - Función de pérdida: cross-entropy
  - Arquitecturas convolucionales (CNN) para imágenes
  - Dropout, batch normalization
- **Modelos Híbridos y Ensamblados:**
  - Stacking con meta-clasificador
  - Voting classifier (hard/soft voting)
  - Bagging con diferentes base estimators

3 Manejo de Datos Desbalanceados

3.1 Detección y Diagnóstico

- **Identificación del problema:**
  - Ratio de desbalance: 10:1, 100:1, 1000:1
  - Clases minoritarias con muy pocas muestras
  - Separabilidad de clases minoritarias
- **Impacto en modelos:**
  - Sesgo hacia clase mayoritaria
  - Métricas engañosas (accuracy paradoja)
  - Dificultad para aprender patrones minoritarios

3.2 Técnicas de Muestreo

- **Sobremuestreo (Oversampling):**
  - Random Oversampling (con repetición)
  - **SMOTE** (Synthetic Minority Oversampling Technique):
    - Crea muestras sintéticas interpolando entre vecinos
    - Variantes: Borderline-SMOTE, SVM-SMOTE
  - **ADASYN** (Adaptive Synthetic Sampling):
    - Genera más muestras donde es más difícil
- **Submuestreo (Undersampling):**
  - Random Undersampling
  - Tomek Links (elimina bordes ambiguos)
  - Condensed Nearest Neighbor
  - NearMiss (selecciona muestras representativas)
- **Métodos híbridos:**

- SMOTE + Tomek
- SMOTE + ENN (Edited Nearest Neighbors)

- **Implementación con imbalanced-learn:**

```
from imblearn.over_sampling import SMOTE
from imblearn.combine import SMOTETomek
from imblearn.pipeline import Pipeline

smote = SMOTE(random_state=42)
pipeline = Pipeline([
    ('sampling', smote),
    ('classifier', RandomForestClassifier())
])
```

3.3 Técnicas a Nivel de Algoritmo

- **Pesos de clase (Class Weights):**
  - Penalizar más errores en clase minoritaria
  - `class_weight='balanced'` en sklearn
  - Pesos personalizados según coste de error
- **Funciones de pérdida sensibles al coste:**
  - Focal Loss (para redes neuronales)
  - Weighted cross-entropy
- **Umbrales de decisión:**
  - Ajuste del umbral óptimo (no usar 0.5 por defecto)
  - Búsqueda de umbral que maximice métrica objetivo
  - Curvas de trade-off (Precision-Recall vs umbral)

3.4 Evaluación con Datos Desbalanceados

- **Estratificación en splits:**
  - `StratifiedKFold` para CV
  - `train_test_split` con stratify=y
  - Mantener proporción de clases en todos los folds
- **Métricas apropiadas:**
  - Matriz de confusión (siempre)
  - Precision, Recall, F1-score (macro, micro, weighted)
  - ROC-AUC (cuidado con datasets muy desbalanceados)
  - Precision-Recall AUC (mejor para desbalance extremo)
  - Cohen's Kappa
  - Matthews Correlation Coefficient (MCC)

Predicción		
		Positiva
Negativa		
2*Real	Positiva	VP
FN		
	Negativa	FP
VN		

Cuadro 1: Matriz de confusión

4 Métricas y Evaluación

4.1 Métricas para Clasificación Binaria

- **Matriz de Confusión:**
- **Métricas derivadas:**
  - **Accuracy:** $\frac{VP+VN}{VP+VN+FP+FN}$
  - **Precision:** $\frac{VP}{VP+FP}$ (de las que dije positivas, ¿cuántas son?)
  - **Recall (Sensitivity):** $\frac{VP}{VP+FN}$ (de las positivas reales, ¿cuántas capturé?)
  - **Specificity:** $\frac{VN}{VN+FP}$
  - **F1-Score:** $2 \cdot \frac{precision \cdot recall}{precision+recall}$
  - **F$_\beta$:** $(1+\beta^2) \cdot \frac{precision \cdot recall}{(\beta^2 \cdot precision)+recall}$

4.2 Métricas para Clasificación Multiclase

- **Promedios:**
  - **Macro:** promedio simple por clase (trata todas por igual)
  - **Micro:** promedio por muestra (trata todas muestras igual)
  - **Weighted:** promedio ponderado por soporte de clase
- **Matriz de confusión multiclase:**
  - Visualización con heatmap
  - Análisis de errores por clase
  - Clases comúnmente confundidas
- **Métricas específicas:**
  - Cohen's Kappa (acuerdo más allá del azar)
  - Matthews Correlation Coefficient (versión multiclase)
  - Log-Loss (cross-entropy)

4.3 Curvas de Evaluación

- **Curva ROC (Receiver Operating Characteristic):**
  - TPR (Recall) vs FPR (1-Specificity)
  - AUC-ROC: área bajo la curva
  - Interpretación: probabilidad de que un positivo tenga score mayor que negativo
- **Curva Precision-Recall:**
  - Mejor para datasets desbalanceados

    - PR-AUC (área bajo curva Precision-Recall)
    - Curva de trade-off entre precisión y recall
- **Curvas de Calibración:**
    - Confiabilidad de probabilidades predichas
    - Diagrama de calibración (frecuencia observada vs predicha)
    - Brier Score: error cuadrático de probabilidades

4.4 Validación Cruzada Específica

- **Estratificada:** mantener proporción de clases
- **GroupKFold:** cuando hay grupos correlacionados
- **Leave-One-Group-Out:** para validación por grupos
- **Validación temporal:** para series temporales con clasificación

5 Calibración de Probabilidades

5.1 Importancia de Probabilidades Bien Calibradas

- **Concepto:** una probabilidad predicha de 0.8 debe corresponder a 80 % de observaciones positivas
- **Modelos mal calibrados:**
    - SVM tiende a producir probabilidades extremas
    - Gradient Boosting puede estar mal calibrado
    - Random Forest mejora con calibración
- **Cuándo es crítico:**
    - Toma de decisiones basada en umbrales
    - Ranking por probabilidad
    - Evaluación de riesgos

5.2 Métodos de Calibración

- **Platt Scaling (Regresión Logística):**
    - Ajusta sigmoide a scores del modelo
    - Parámetros aprendidos en validación
    - Funciona bien para SVM
- **Isotonic Regression:**
    - Ajuste no paramétrico monótono
    - Más flexible pero requiere más datos
    - Puede sobreajustar con pocos datos
- **Temperature Scaling:**
    - Escala logits con un parámetro T
    - Mantiene el orden de predicciones
    - Popular en deep learning
- **Implementación:**

```python
from sklearn.calibration import CalibratedClassifierCV

# Calibraci n con Platt Scaling
calibrated_clf = CalibratedClassifierCV(
    base_estimator=svm_clf,
    method='sigmoid',
    cv=5
)
calibrated_clf.fit(X_train, y_train)
```

6 Selección de Modelos y Optimización

6.1 Búsqueda de Hiperparámetros Específicos

- **Métricas de optimización:**
  - Elegir métrica relevante para negocio
  - Optimizar F1, ROC-AUC, Precision@K según caso
  - Usar scoring personalizado en GridSearchCV
- **Hiperparámetros clave por modelo:**
  - **Regresión Logística:** C, penalty, solver
  - **SVM:** C, gamma (para RBF), kernel
  - **Random Forest:** n_estimators, max_depth, min_samples_split, class_weight
  - **XGBoost:** learning_rate, max_depth, subsample, colsample_bytree, scale_pos_weight
  - **Redes Neuronales:** learning_rate, dropout, batch_size, epochs
- **Búsqueda avanzada:**
  - Optuna para optimización bayesiana
  - Hyperopt
  - GridSearch con validación estratificada

6.2 Comparación de Modelos

- **Tabla comparativa multicriterio:**

Modelo	Accuracy	F1	AUC-ROC	Tiempo	Calibración
Log. Regresión	0.82	0.79	0.88	0.1s	Excelente
SVM (RBF)	0.85	0.83	0.91	2.3s	Mala
Random Forest	0.87	0.86	0.93	4.1s	Buena
XGBoost	0.89	0.88	0.95	3.2s	Regular

Cuadro 2: Comparación de modelos de clasificación

- **Pruebas estadísticas:**
  - Test de McNemar para comparar clasificadores
  - Test de Friedman + Nemenyi para múltiples modelos
  - Cross-Validation paired t-test

7 Interpretabilidad y Explicabilidad

7.1 Importancia de Variables en Clasificación

- **Coeficientes e importancia:**
  - Regresión Logística: odds ratios (e^{β_j})
  - Árboles: impurity decrease
  - Permutation importance (específico para clasificación)
- **Visualizaciones:**
  - Gráfico de coeficientes con intervalos
  - Importancia por clase (para multiclase)
  - Word clouds de features importantes

7.2 Métodos Globales

- **Partial Dependence Plots (PDP) para clasificación:**
  - Probabilidad predicha vs feature
  - Efecto marginal en escala de probabilidad
  - `sklearn.inspection.plot_partial_dependence`
- **Individual Conditional Expectation (ICE):**
  - Líneas individuales por observación
  - Detecta heterogeneidad de efectos
- **SHAP Global para clasificación:**
  - SHAP values en escala de log-odds
  - Summary plots por clase
  - Dependence plots con interacciones

7.3 Métodos Locales

- **LIME para clasificación:**
  - Explica predicciones individuales
  - Features más influyentes en decisión
  - Útil para auditoría de casos
- **SHAP Local:**
  - Waterfall plots
  - Force plots
  - Contribución de cada feature a probabilidad
- **Contrafactuales y AD:**
  - "¿Qué cambiaría para que la predicción fuera otra clase?"
  - Mínimos cambios necesarios
  - Explicaciones accionables

7.4 Interpretación Específica por Modelo

- **Regresión Logística:**
  - β_j: cambio en log-odds por unidad de x_j
  - e^{β_j}: odds ratio (multiplicativo)
  - Margen de decisión lineal
- **Árboles de Decisión:**
  - Reglas de decisión: "si $x > t$, entonces..."
  - Camino de decisión por observación
  - Importancia por frecuencia de splits
- **SVM:**
  - Vectores de soporte (muestras que definen frontera)
  - Kernel trick dificulta interpretación directa
  - Uso de explicaciones post-hoc

8 Problemas Comunes y Soluciones

8.1 Overfitting en Clasificación

- **Síntomas:**
  - Accuracy perfecta en train, baja en test
  - Fronteras de decisión demasiado complejas
  - Alta varianza en predicciones
- **Soluciones específicas:**
  - Regularización (C pequeña en SVM/LR)
  - Poda en árboles (max_depth, min_samples_leaf)
  - Dropout en redes neuronales
  - Early stopping en boosting
  - Aumento de datos (data augmentation)

8.2 Underfitting

- **Síntomas:**
  - Bajo rendimiento en train y test
  - Fronteras demasiado simples
  - No captura patrones obvios
- **Soluciones:**
  - Aumentar complejidad del modelo
  - Reducir regularización
  - Crear más features (interacciones, polinomios)
  - Probar modelos no lineales

8.3 Clases Superpuestas

- **Problema:** regiones del espacio con mezcla de clases
- **Soluciones:**
  - Modelos probabilísticos (estiman incertidumbre)
  - Features más discriminantes
  - Revisar labeling (posible ruido)
  - Aceptar que hay límite irreducible de error (Bayes error rate)

8.4 Inestabilidad de Modelos

- **Problema:** pequeñas variaciones en datos cambian mucho predicciones
- **Soluciones:**
  - Ensamblados (Random Forest, Bagging)
  - Regularización
  - Validación con múltiples semillas

9 Técnicas Avanzadas

9.1 Clasificación Multiclase y Multi-etiqueta

- **Estrategias multiclase:**
  - One-vs-Rest (OvR): K clasificadores binarios
  - One-vs-One (OvO): $\frac{K(K-1)}{2}$ clasificadores
  - Softmax/Multinomial directo
- **Multi-etiqueta:**
  - Varias etiquetas por muestra
  - Binary Relevance (independiente por etiqueta)
  - Classifier Chains (considera dependencias)
  - MLkNN (adaptación de KNN)
- **Métricas específicas:**
  - Hamming Loss
  - Subset Accuracy (exact match)
  - Jaccard Index

9.2 Clasificación con Datos Secuenciales

- **Modelos secuenciales:**
  - HMM (Hidden Markov Models)
  - CRF (Conditional Random Fields)
  - LSTM/GRU para secuencias
  - Transformers (BERT, etc.)
- **Características específicas:**
  - Contexto temporal
  - Dependencias de largo plazo
    item Features de ventana deslizante

9.3 Learning to Rank

- **Aplicaciones:** búsqueda, recomendación
- **Enfoques:**
  - Pointwise: regresión/clasificación sobre relevancia
  - Pairwise: comparar pares de items
  - Listwise: optimizar métrica de ranking
- **Métricas:** NDCG, MAP, MRR

9.4 Active Learning para Clasificación

- **Concepto:** seleccionar muestras más informativas para etiquetar
- **Estrategias de muestreo:**
  - Uncertainty sampling (menos confianza)
  - Query by committee (disenso entre modelos)
  - Expected model change
- **Útil cuando:**
  - Etiquetado costoso
  - Clases desbalanceadas
  - Grandes volúmenes de datos no etiquetados

10 Producción y Mantenimiento

10.1 Despliegue de Clasificadores

- **Consideraciones específicas:**
  - Tiempo de inferencia (latencia)
  - Probabilidades calibradas vs clases duras
  - Manejo de clases no vistas
- **Formatos de exportación:**
  - ONNX para interoperabilidad
  - PMML para sistemas legacy
  - TensorFlow SavedModel / PyTorch
  - MLflow

10.2 Monitoreo en Producción

- **Métricas de rendimiento:**
  - Seguimiento de accuracy, F1, precision, recall
  - Matriz de confusión en tiempo real
  - Comparación con baseline
- **Data drift:**
  - Cambios en distribución de features por clase
  - Nuevas categorías en variables
  - Detección con PSI (Population Stability Index)

- **Concept drift:**
  - Cambios en relación features-clase
  - Detección con ventanas deslizantes
  - Reentrenamiento automático

10.3 Mantenimiento y Actualización

- **Estrategias de reentrenamiento:**
  - Periódico (diario, semanal, mensual)
  - Basado en detección de drift
  - Continuo (online learning)
- **Versionado:**
  - Datos de entrenamiento
  - Hiperparámetros
  - Métricas de validación
- **A/B testing:**
  - Comparar versiones en producción
  - Evaluar impacto en negocio

11 Checklist de Implementación

- **Análisis Inicial**
  - ☐ Distribución de clases (balanceo)
  - ☐ Separabilidad visual (PCA/t-SNE)
  - ☐ Identificar clase de interés (target)
- **Preparación**
  - ☐ Split estratificado
  - ☐ Decidir estrategia para desbalanceo
  - ☐ Escalado (si necesario)
- **Modelos Baseline**
  - ☐ DummyClassifier (mayoritaria, estratificada)
  - ☐ Regresión Logística simple
  - ☐ Árbol de decisión poco profundo
- **Manejo de Desbalanceo**
  - ☐ Probar class_weight='balanced'
  - ☐ Evaluar SMOTE/otras técnicas
  - ☐ Ajustar umbral de decisión
- **Modelos Avanzados**
  - ☐ Random Forest con class_weight
  - ☐ XGBoost con scale_pos_weight
  - ☐ SVM con kernel RBF
- **Optimización**

  - ☐ Búsqueda de hiperparámetros
  - ☐ Validación cruzada estratificada
  - ☐ Comparación estadística
- **Evaluación Exhaustiva**
  - ☐ Múltiples métricas (no solo accuracy)
  - ☐ Curva ROC y Precision-Recall
  - ☐ Matriz de confusión
  - ☐ Calibración de probabilidades
- **Interpretación**
  - ☐ Importancia de variables
  - ☐ SHAP/LIME para casos test
  - ☐ Partial Dependence Plots
- **Producción**
  - ☐ Pipeline completo y reproducible
  - ☐ Tests de calidad
  - ☐ Monitoreo de drift
  - ☐ Plan de reentrenamiento

12 Casos de Uso Comunes y Consideraciones

12.1 Clasificación Binaria Típica

- **Ejemplos:** churn, fraude, conversión, default
- **Métrica principal:** depende del coste de FP vs FN
- **Consideraciones:** umbral óptimo según negocio

12.2 Clasificación Multiclase

- **Ejemplos:** clasificación de imágenes, diagnóstico, segmentación
- **Desafíos:** confusión entre clases similares
- **Estrategia:** jerárquica si hay relaciones entre clases

12.3 Detección de Anomalías

- **Características:** desbalance extremo (99.9 % normal)
- **Enfoques:** One-Class SVM, Isolation Forest, Autoencoders
- **Métricas:** Precision@k, Recall@k

12.4 Clasificación con Restricciones

- **Justicia (Fairness):** evitar sesgos por grupo
- **Interpretabilidad obligatoria:** sectores regulados
- **Tiempo real:** latencia ¡100ms

13 Conclusiones y Buenas Prácticas

- **Conoce tu negocio:** el coste de FP vs FN define la métrica óptima
- **Desbalanceo es la regla, no la excepción:** planifica estrategia
- **Accuracy es engañosa:** usa múltiples métricas
- **Probabilidades calibradas:** si tomas decisiones basadas en ellas
- **Interpretabilidad:** cada vez más crítica (regulaciones, confianza)
- **Validación robusta:** estratificación siempre
- **Monitoreo continuo:** los datos cambian, los modelos también deben hacerlo