Sesión 4

Clasificación I: Regresión Logística y Métricas

Carlos César Sánchez Coronel

MACHINE LEARNING

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

¿Por qué no regresión lineal para clasificación?

- Predicciones fuera del rango $[0, 1]$ (no interpretables como probabilidad).
- Errores no homocedásticos (varianza variable).
- Relación no lineal; la sigmoide es más adecuada.

Conclusión

La regresión logística modela directamente la probabilidad de pertenencia a una clase.

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

Función Sigmoide

Definición

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z \in \mathbb{R}$$

- $\sigma(z) \to 0$ cuando $z \to -\infty$
- $\sigma(z) \to 1$ cuando $z \to +\infty$
- $\sigma(0) = 0{,}5$
- Monótona creciente y diferenciable.

Modelo Probabilístico

Probabilidad de clase positiva

$$P(y = 1|\mathbf{x}) = \sigma(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p) = \frac{1}{1 + e^{-(\beta_0 + \boldsymbol{\beta}^T \mathbf{x})}}$$

$P(y = 0|\mathbf{x}) = 1 - P(y = 1|\mathbf{x})$.

Interpretación con log-odds

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}$$

Cada β_j mide el cambio en log-odds por unidad de x_j.

Interpretación de Coeficientes: Odds Ratio

- **Odds ratio:** e^{β_j}.
- Si $e^{\beta_j} > 1$, la variable aumenta las odds de la clase positiva.
- Si $e^{\beta_j} < 1$, la variable disminuye las odds.

Ejemplo

En un modelo de riesgo crediticio, $\beta_{\text{ingresos}} = -0{,}05$ implica $e^{-0{,}05} \approx 0{,}951$, es decir, por cada unidad de ingreso adicional, las odds de default se reducen en un 4,9 %.

Función de Pérdida: Log-Loss (Entropía Cruzada)

Para una muestra

$$\mathcal{L}(\hat{p}, y) = -[y \log(\hat{p}) + (1 - y) \log(1 - \hat{p})]$$

Para todo el conjunto

$$J(\beta) = -\frac{1}{n} \sum_{i=1}^{n} [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]$$

- Convexa $\rightarrow$ mínimo global único.
- Diferenciable $\rightarrow$ apta para gradiente descendente.

Optimización: Gradiente Descendente

Gradiente de la log-loss

$$\nabla J(\boldsymbol{\beta}) = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i)\mathbf{x}_i$$

Misma forma que en regresión lineal, pero con $\hat{p}_i$ definido por la sigmoide.

- Actualización: $\boldsymbol{\beta} := \boldsymbol{\beta} - \alpha\nabla J(\boldsymbol{\beta})$.
- Se pueden usar variantes: SGD, mini-batch.

Límite de Decisión

Definición

Puntos donde $P(y = 1|\mathbf{x}) = 0{,}5$, es decir:

$$\beta_0 + \boldsymbol{\beta}^T \mathbf{x} = 0$$

- En 2D: una recta.
- En 3D: un plano.
- En dimensiones superiores: un hiperplano.

L

a regresión logística es un **clasificador lineal**.

Regularización en Regresión Logística

Ridge (L2)

$J_{\text{ridge}} = J + \lambda \sum \beta_j^2$

- Encoge coeficientes, pero no los anula.

Lasso (L1)

$J_{\text{lasso}} = J + \lambda \sum |\beta_j|$

- Puede fijar coeficientes a cero $\rightarrow$ selección de variables.

- Útil con muchas variables para evitar sobreajuste.
- Elastic Net combina ambas.

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

Matriz de Confusión

	Real Positivo	**Real Negativo**
Pred. Positivo	VP (Verdaderos Positivos)	FP (Falsos Positivos)
Pred. Negativo	FN (Falsos Negativos)	VN (Verdaderos Negativos)

- VP: spam correcto; FP: legítimo marcado como spam.
- FN: spam no detectado; VN: legítimo correcto.

Métricas Derivadas

Exactitud (Accuracy)

$$\frac{VP+VN}{VP+VN+FP+FN}$$

Recall (Sensibilidad)

$$\frac{VP}{VP+FN}$$

Precisión (Precision)

$$\frac{VP}{VP+FP}$$

F1-Score

$$2 \cdot \frac{\text{Prec} \cdot \text{Recall}}{\text{Prec} + \text{Recall}}$$

Ejemplo fraude (Pregunta 8)

VP=15, FP=5, FN=5, VN=75 $\rightarrow$ Precision=0.75, Recall=0.75, F1=0.75.

Comparación de Métricas (Ejemplo Médico)

Dos modelos para enfermedad rara (prevalencia 1 %):

Modelo	**Precisión**	**Recall**	**F1**
A	0.444	0.80	0.57
B	0.091	1.00	0.17

- Si FN es muy costoso $\rightarrow$ elegir B (recall 1.0).
- Si FP es muy costoso $\rightarrow$ elegir A (mejor precisión).

Curva ROC y AUC

Curva ROC

- Eje X: Tasa de Falsos Positivos (FPR)
- Eje Y: Tasa de Verdaderos Positivos (TPR = Recall)
- Cada punto = un umbral diferente.

AUC (Area Under Curve)

- AUC = 0.5: clasificador aleatorio.
- AUC = 1.0: clasificador perfecto.
- Probabilidad de que un positivo tenga score mayor que un negativo.

Cuándo usar cada métrica

- **Accuracy:** clases balanceadas, costos simétricos.
- **Precision:** minimizar falsos positivos (ej. spam, diagnósticos graves).
- **Recall:** minimizar falsos negativos (ej. fraude, screening).
- **F1:** balance entre precisión y recall, clases desbalanceadas.
- **AUC-ROC:** comparación global de modelos independiente del umbral.

¡Cuidado!

En gran desbalance, AUC-ROC puede ser optimista; usar curva Precision-Recall (PR-AUC).

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

Técnicas de Muestreo

Undersampling

Reducir clase mayoritaria.

- Ventaja: reduce datos.
- Desventaja: pierde información.

Oversampling

Duplicar clase minoritaria.

- Puede causar sobreajuste.

SMOTE

Genera muestras sintéticas interpolando.

$$\mathbf{x}_{\text{nuevo}} = \mathbf{x}_i + \lambda(\mathbf{x}_j - \mathbf{x}_i)$$

Más robusto que oversampling simple.

Técnicas a Nivel de Algoritmo

Pesos en la función de pérdida

$$J_{\text{pond}} = -\frac{1}{n} \sum \left[w_1 y \log(\hat{p}) + w_0 (1 - y) \log(1 - \hat{p}) \right]$$

Pesos típicamente inversamente proporcionales a la frecuencia.

Ajuste del umbral

- Disminuir umbral para favorecer recall (detectar más positivos).
- Aumentar umbral para favorecer precisión.

Evaluación en Problemas Desbalanceados

- Evitar accuracy.
- Usar matriz de confusión, precisión, recall, F1 (especialmente para la clase minoritaria).
- Curva Precision-Recall y su área (PR-AUC) más informativa que ROC-AUC.

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

Contexto y Preprocesamiento

- **Datos:** pacientes con características clínicas (edad, presión, glucosa...).
- **Objetivo:** detectar enfermedad rara (prevalencia 10 %).
- **Preprocesamiento:**
  - Estandarización de variables numéricas.
  - Imputación de nulos.
  - División estratificada (70/30).

Modelado y Evaluación

Estrategias probadas:

1. Sin tratamiento del desbalance.
2. Con pesos de clase.
3. Con SMOTE.

Métricas en prueba:

- Matriz de confusión.
- Precisión, recall, F1 para clase positiva.
- AUC-ROC y AUC-PR.

Resultados esperados

Sin tratamiento: bajo recall. Con pesos o SMOTE: mejora recall (a costa de precisión). La elección depende del costo de FN vs FP.

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

Diseño de un sistema antifraude

- 10M transacciones/día, fraude 0.1 %.
- Requisitos: interpretabilidad (regulatorio), velocidad (ms), buena detección.

Feature engineering específico

1. Log del monto.
2. Hora del día (codificación cíclica seno/coseno).
3. Agregadas por usuario: frecuencia últimas 24h, monto promedio, desviación.
4. Ratios: monto actual vs promedio del usuario.
5. Puntuación de anomalía (Isolation Forest) como predictor.

Manejo del desbalance extremo

- **Nivel datos:** SMOTE (cuidado con ruido) o undersampling.
- **Nivel algoritmo:** pesos de clase y ajuste de umbral.
- **Métricas:** recall, precisión, F1, curva PR.

Monitoreo en producción

- Técnicas: recall $\leftrightarrow$ fraude no detectado; precisión $\leftrightarrow$ transacciones legítimas bloqueadas.
- Impacto de falsos positivos: cliente insatisfecho, costo de atención.

Contenido

1. Introducción a la Clasificación
2. Regresión Logística
3. Evaluación de Clasificadores Binarios
4. Manejo de Clases Desbalanceadas
5. Caso de Estudio: Diagnóstico Médico
6. Caso Avanzado: Detección de Fraude
7. Resumen y Conexión

Lo que hemos aprendido

Conceptos clave

- Regresión logística: modelo probabilístico, sigmoide, log-loss, límite lineal.
- Interpretación mediante odds ratios.
- Evaluación: matriz de confusión, precisión, recall, F1, ROC/AUC.
- Manejo de clases desbalanceadas: muestreo (SMOTE), pesos, umbral.
- Aplicación a casos reales (spam, fraude, diagnóstico médico).

¡Gracias!