Sesión 8

Evaluación y Validación de Modelos: Generalización, sesgo-varianza y optimización de hiperparámetros

Carlos César Sánchez Coronel

MACHINE LEARNING

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Definición y causas

Underfitting

- Modelo demasiado simple para capturar la estructura.
- Alto error en entrenamiento y prueba.
- Causas: poca complejidad, características insuficientes, regularización excesiva.

Overfitting

- Modelo se ajusta al ruido, no a la señal.
- Error muy bajo en entrenamiento, alto en prueba.
- Causas: modelo complejo, pocos datos, entrenamiento excesivo, falta de regularización.

Diagnóstico y soluciones

Problema	**Posibles soluciones**
Underfitting	Aumentar complejidad, añadir características, reducir regularización, aumentar número de iteraciones.
Overfitting	Reducir complejidad, aumentar regularización, más datos, early stopping, simplificar modelo.

- Herramientas gráficas: curvas de aprendizaje, curvas de validación.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Descomposición del error esperado

Para un punto fijo x_0

$$\mathbb{E}\left[(y_0 - \hat{f}(x_0))^2\right] = \text{Sesgo}^2 + \text{Varianza} + \text{Ruido irreducible}$$

- **Sesgo**: error por suposiciones erróneas (diferencia entre predicción promedio y valor real).
- **Varianza**: variabilidad de las predicciones al cambiar el conjunto de entrenamiento.
- **Ruido**: error inherente a los datos, irreducible.

Relación con la complejidad

- Modelos simples $\rightarrow$ alto sesgo, baja varianza.
- Modelos complejos $\rightarrow$ bajo sesgo, alta varianza.
- El error total tiene un mínimo en el punto de equilibrio.

Diagnóstico práctico

- Alto sesgo: errores altos en entrenamiento y validación.
- Alta varianza: error bajo en entrenamiento, alto en validación.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

k-Fold Cross-Validation

Procedimiento

1. Dividir datos en k pliegues.
2. Para $i = 1..k$: entrenar con $k-1$ pliegues, validar en el i-ésimo.
3. Error promedio $= \frac{1}{k}\sum_{i=1}^{k} \text{error}_i$.

Elección de k

- $k = 5$ o 10 típicos.
- k grande $\rightarrow$ menor sesgo, mayor varianza y costo.
- $k = n$ (LOOCV): máximo costo, alta varianza.

Stratified k-Fold y LOOCV

- **Stratified k-Fold**: mantiene proporción de clases en cada pliegue. Obligatorio en clasificación con desbalance.
- **Leave-One-Out (LOOCV)**: $k = n$. Entrena con todas menos una observación. Útil con pocos datos, pero costoso y de alta varianza.

Validación cruzada en series temporales

¡No usar k-fold estándar!

Viola la dependencia temporal (usa datos futuros para predecir pasado).

Expanding window

- Entrenamiento crece, validación fija.

Rolling window

- Ventana de tamaño fijo se desliza.

En scikit-learn: `TimeSeriesSplit`.

Estimación del error y su varianza

Ejemplo numérico

Errores en 5-fold: [0.15, 0.12, 0.18, 0.14, 0.16]

- Media $= 0.15$
- Desviación estándar ≈ 0.02

El error esperado es $0{,}15 \pm 0{,}02$.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Construcción e interpretación

- Muestran error en entrenamiento y validación vs. tamaño del conjunto de entrenamiento.
- Se construyen entrenando el modelo con subconjuntos crecientes.

Alto sesgo

- Curvas convergen a error alto.
- Añadir datos no ayuda.

Alta varianza

- Gran brecha entre curvas.
- Añadir datos reduce la brecha.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Grid Search

Definición

Prueba todas las combinaciones de una rejilla de valores.

- Ventaja: exhaustivo.
- Desventaja: costo exponencial en número de parámetros.

Ejemplo

`param_grid = {'max_depth': [3,5,7], 'learning_rate': [0.01,0.1,0.3], 'n_estimators': [100,200]}`

$3 \times 3 \times 2 = 18$ combinaciones.

Random Search

- Muestrea aleatoriamente combinaciones de una distribución.
- Más eficiente que Grid Search en espacios de alta dimensión.
- Con el mismo presupuesto, explora más valores por parámetro.

Bayesian Optimization

Idea

Construye un modelo probabilístico (Gaussian Process) de la función objetivo y lo usa para decidir el próximo punto a evaluar.

- Función de adquisición: *Expected Improvement*, *Upper Confidence Bound*.
- Requiere menos evaluaciones que Random Search, ideal para modelos costosos.

Implementaciones: Optuna, Hyperopt, Scikit-Optimize.

Comparación de métodos

Método	**Exhaustividad**	**Eficiencia**	**Aplicación típica**
Grid Search	Alta	Baja	Pocos parámetros, valores discretos
Random Search	Media	Media	Muchos parámetros, presupuesto limitado
Bayesian Opt.	Adaptativa	Alta	Modelos costosos, muchas evaluaciones

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Data Leakage (Fuga de datos)

Error común

Usar información del conjunto de prueba o validación durante el entrenamiento.

Ejemplos

- Estandarizar con media y desviación de todo el dataset antes de dividir.
- Hacer oversampling (SMOTE) antes de dividir.
- Seleccionar características usando todo el dataset.
- Target encoding con media global.

Cómo evitar leakage

1. Siempre dividir primero: entrenamiento / validación / prueba.
2. Ajustar transformaciones (escalado, imputación, codificación) solo en entrenamiento, luego aplicar a validación/prueba.
3. Usar validación cruzada para selección de características o target encoding.
4. En series temporales, respetar el orden.
5. En datos con grupos, usar `GroupKFold`.

Validación con grupos y entrenamiento final

- **GroupKFold**: asegura que todas las muestras de un mismo grupo (ej. paciente) estén en el mismo pliegue.
- Una vez elegidos hiperparámetros, entrenar el modelo final con **todos los datos disponibles** (entrenamiento + validación) y evaluar una sola vez en el conjunto de prueba.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Selección de hiperparámetros para XGBoost

- Problema: clasificación binaria, 50,000 muestras, 20 características, clases balanceadas.
- Pasos:
  1. Dividir en entrenamiento (70 %), validación (15 %), prueba (15 %).
  2. Elegir hiperparámetros a optimizar: `learning_rate`, `max_depth`, `subsample`, `colsample_bytree`, `lambda`, `alpha`.
  3. Usar `RandomizedSearchCV` o `Optuna` con validación cruzada (5-fold).
  4. Evaluar el mejor modelo en el conjunto de prueba.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Métricas según el problema

- **Clasificación**: accuracy, AUC, F1, log-loss. Elegir según desbalance y objetivos.
- **Regresión**: RMSE, MAE, RMSLE, R^2.
- En validación cruzada, se promedia la métrica y se reporta su desviación.

Ejemplo con alta varianza

Modelo A: errores [0.10,0.12,0.11,0.13,0.09] (media=0.11, sd=0.016)
Modelo B: errores [0.05,0.20,0.04,0.22,0.06] (media=0.114, sd=0.083)
Se prefiere el modelo A por estabilidad.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Importancia de la validación

- Todas las sesiones anteriores (regresión, clasificación, árboles, boosting) requieren evaluación rigurosa.
- La elección de hiperparámetros es crítica para el rendimiento final.
- Técnicas vistas aquí se aplican a cualquier modelo supervisado o no supervisado.
- Conceptos de sesgo-varianza subyacen a la regularización y complejidad.

Contenido

1. Underfitting y Overfitting
2. Compromiso Sesgo-Varianza
3. Validación Cruzada (Cross-Validation)
4. Curvas de Aprendizaje
5. Búsqueda de Hiperparámetros
6. Consideraciones Prácticas
7. Caso Integrado: XGBoost
8. Métricas en Validación Cruzada
9. Conexión con el resto del curso
10. Resumen

Lo que hemos aprendido

Conceptos clave

- **Underfitting / Overfitting**: diagnóstico y soluciones.
- **Sesgo-Varianza**: descomposición del error y trade-off.
- **Validación cruzada**: k-fold, stratified, LOOCV, time series.
- **Curvas de aprendizaje**: identifican sesgo/varianza.
- **Búsqueda de hiperparámetros**: Grid, Random, Bayesian.
- **Data leakage**: cómo evitarlo.
- **Grupos y evaluación final**.

¡Gracias!