# Temario Completo: Modelos de Clustering

Aprendizaje no supervisado para segmentación y descubrimiento de patrones

9 de marzo de 2026

**Resumen**

Este documento presenta un temario exhaustivo para el desarrollo de modelos de clustering (segmentación). Cubre desde la preparación específica de datos no etiquetados, los principales algoritmos de clustering, métodos para determinar el número óptimo de clusters, evaluación sin ground truth, interpretación de segmentos, visualización de alta dimensionalidad, y consideraciones para implementación en producción. Ideal para segmentación de clientes, análisis de perfiles y descubrimiento de patrones.

## Índice

**1. Fundamentos y Preparación para Clustering** **3**
1.1. Conceptos Fundamentales . . . 3
1.2. Preparación Específica para Clustering . . . 3
1.3. Medidas de Distancia/Similitud . . . 4

**2. Algoritmos de Clustering** **4**
2.1. Clustering Particional: K-Means y Variantes . . . 4
2.2. Clustering Jerárquico . . . 5
2.3. Clustering Basado en Densidad: DBSCAN y OPTICS . . . 6
2.4. Clustering Basado en Distribuciones . . . 7
2.5. Clustering Avanzado y Especializado . . . 7

**3. Determinación del Número de Clusters (k)** **8**
3.1. Métodos Heurísticos . . . 8
3.2. Métodos Específicos por Algoritmo . . . 9
3.3. Validación Cruzada para Clustering . . . 9

**4. Evaluación de Clustering** **9**
4.1. Métricas Internas (sin ground truth) . . . 9
4.2. Métricas Externas (con ground truth) . . . 10
4.3. Validación Visual . . . 10

**5. Interpretación y Perfilado de Clusters** **10**
5.1. Caracterización de Clusters . . . 10
5.2. Naming y Descripción de Segmentos . . . 11
5.3. Validación con Stakeholders . . . 11

**6. Problemas Comunes y Soluciones** **11**
6.1. Escala y Normalización . . . 11
6.2. Maldición de la Dimensionalidad . . . 11
6.3. Clusters de Diferentes Tamaños y Densidades . . . 11
6.4. Outliers y Ruido . . . 12
6.5. Inicialización y Estabilidad . . . 12

**7. Técnicas Avanzadas** **12**
7.1. Clustering con Datos Mixtos . . . 12
7.2. Clustering Jerárquico con Grandes Datasets . . . 12
7.3. Ensamblado de Clustering . . . 12
7.4. Clustering con Restricciones (Semi-supervisado) . . . 13
7.5. Clustering Temporal y de Series . . . 13
7.6. Clustering en Streaming . . . 13

**8. Casos de Uso y Aplicaciones** **13**
8.1. Segmentación de Clientes (Marketing) . . . 13
8.2. Segmentación de Productos . . . 13
8.3. Detección de Anomalías . . . 13
8.4. Compresión y Cuantización . . . 13
8.5. Análisis de Imágenes y Visión . . . 13
8.6. Bioinformática y Genómica . . . 14
8.7. Análisis de Redes Sociales . . . 14

**9. Producción y Mantenimiento** **14**
9.1. Asignación de Nuevos Puntos . . . 14
9.2. Serialización y Despliegue . . . 14
9.3. Monitoreo de Estabilidad Temporal . . . 14
9.4. Actualización del Modelo . . . 15

**10. Checklist de Implementación** **15**

**11. Herramientas y Librerías Útiles** **16**

**12. Conclusiones y Buenas Prácticas** **16**

**13. Apéndice: Comparativa de Algoritmos** **16**

# 1 Fundamentos y Preparación para Clustering

## 1.1 Conceptos Fundamentales

- **Definición:** Aprendizaje no supervisado que agrupa observaciones similares
- **Objetivos principales:**
  - Descubrir estructura inherente en datos
  - Segmentación para estrategias diferenciadas
  - Reducción de dimensionalidad (prototipos)
  - Detección de anomalías (outliers como clusters pequeños)
- **Tipos de clustering:**
  - Particional (k-means, PAM)
  - Jerárquico (aglomerativo, divisivo)
  - Basado en densidad (DBSCAN, OPTICS)
  - Basado en distribuciones (GMM)
  - Basado en grafos (Spectral clustering)

## 1.2 Preparación Específica para Clustering

- **Escalado de variables:** CRÍTICO para clustering
  - K-means: sensible a escalas diferentes
  - Estandarización (Z-score) recomendada
  - Min-Max para rangos uniformes
  - Variables con mayor magnitud dominan la distancia
- **Manejo de variables categóricas:**
  - One-Hot Encoding (aumenta dimensionalidad)
  - Gower distance para mixtas
  - K-prototypes (extensión k-means para mixtas)
  - Distance metric learning
- **Reducción de dimensionalidad previa:**
  - PCA para eliminar ruido
  - t-SNE/UMAP solo para visualización, no para clustering
  - Selección de features relevantes
- **Detección de outliers:**
  - Outliers pueden formar clusters propios
  - Considerar eliminación si distorsionan
  - Alternativa: algoritmos robustos (DBSCAN)

### 1.3 Medidas de Distancia/Similitud

- **Para variables numéricas:**
  - **Euclidiana:** $d(x, y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2}$
  - **Manhattan:** $d(x, y) = \sum_{i=1}^{n} |x_i - y_i|$
  - **Coseno:** $sim(x, y) = \frac{x \cdot y}{\|x\|\|y\|}$ (para vectores)
  - **Correlación:** patrones, no magnitudes
  - **Minkowski:** generalización (orden p)
  - **Mahalanobis:** tiene en cuenta correlaciones
- **Para variables categóricas:**
  - **Hamming:** proporción de atributos diferentes
  - **Jaccard:** para conjuntos/binarías
  - **Simple Matching Coefficient**
- **Para datos mixtos:**
  - **Gower distance:** promedio ponderado de distancias por tipo
  - Normalización específica por variable
- **Importancia:** la elección de distancia determina la forma de los clusters

## 2 Algoritmos de Clustering

### 2.1 Clustering Particional: K-Means y Variantes

- **K-Means:**
  - Algoritmo:
    1. Inicializar k centroides aleatorios
    2. Asignar cada punto al centroide más cercano
    3. Recalcular centroides como media del cluster
    4. Repetir 2-3 hasta convergencia
  - Optimización: minimizar inercia (suma de distancias al cuadrado)
  - **Supuestos:** clusters esféricos, mismo tamaño, mismo radio
  - **Ventajas:** rápido, escalable, interpretable
  - **Limitaciones:** requiere k, sensible a inicialización
- **K-Means++:**
  - Inicialización inteligente: centroides alejados
  - Mejora convergencia y resultados
  - Implementado en sklearn por defecto
- **K-Medoids (PAM - Partition Around Medoids):**
  - Usa puntos reales como centroides (medoids)
  - Más robusto a outliers
  - Acepta cualquier matriz de distancia
  - Más costoso computacionalmente
- **K-Means Mini-Batch:**
  - Usa submuestras para actualizar centroides
  - Mucho más rápido en grandes datasets

- Ligera pérdida de precisión

- **Implementación:**

```
from sklearn.cluster import KMeans

kmeans = KMeans(n_clusters=5, init='k-means++', random_state=42)
kmeans.fit(X_scaled)
labels = kmeans.labels_
centroids = kmeans.cluster_centers_
```

## 2.2 Clustering Jerárquico

- **Tipos:**
  - **Aglomerativo (bottom-up):** cada punto es un cluster, se fusionan
  - **Divisivo (top-down):** un cluster se divide recursivamente
- **Métodos de linkage (cómo medir distancia entre clusters):**
  - **Single linkage:** distancia mínima entre puntos
    - Tiende a formar clusters alargados (efecto çadena")
    - Sensible a ruido
  - **Complete linkage:** distancia máxima entre puntos
    - Tiende a clusters compactos
    - Menos sensible a ruido
  - **Average linkage:** distancia promedio entre puntos
  - **Ward's method:** minimiza varianza intra-cluster
    - Similar a k-means pero jerárquico
    - Tiende a clusters del mismo tamaño
  - **Centroid linkage:** distancia entre centroides
- **Dendrograma:**
  - Visualización de la jerarquía
  - Altura = distancia de fusión
  - Cortar a cierta altura para obtener k clusters
- **Ventajas:**
  - No requiere k predefinido
  - Proporciona estructura jerárquica
  - Dendrograma informativo
- **Desventajas:**
  - Costoso: $O(n^3)$ o $O(n^2 \log n)$
  - No escala bien a grandes datasets
  - Decisiones de fusión son definitivas
- **Implementación:**

```
from scipy.cluster.hierarchy import dendrogram, linkage, fcluster
from sklearn.cluster import AgglomerativeClustering

# Con sklearn
hc = AgglomerativeClustering(n_clusters=5, linkage='ward')
labels = hc.fit_predict(X_scaled)
```

```
# Con scipy (m s flexible)
Z = linkage(X_scaled, method='ward')
dendrogram(Z)
labels = fcluster(Z, t=5, criterion='maxclust')
```

## 2.3 Clustering Basado en Densidad: DBSCAN y OPTICS

- **DBSCAN (Density-Based Spatial Clustering):**
  - **Conceptos:**
    - **eps ($\epsilon$):** radio de vecindad
    - **minPts:** mínimo número de puntos en vecindad para ser núcleo
    - **Core point:** tiene al menos minPts en radio $\epsilon$
    - **Border point:** alcanzable desde core pero no es core
    - **Noise point:** no alcanzable desde ningún core
  - **Algoritmo:** expande clusters desde core points
  - **Ventajas:**
    - No requiere k predefinido
    - Detecta clusters de forma arbitraria
    - Identifica outliers automáticamente
  - **Limitaciones:**
    - Sensible a parámetros eps y minPts
    - Dificultad con densidades variables
    - No escala bien (índices espaciales ayudan)
- **OPTICS (Ordering Points To Identify Clustering Structure):**
  - Extensión de DBSCAN que maneja densidades variables
  - No requiere eps fijo
  - Produce un ordenamiento basado en alcanzabilidad
  - Se puede extraer clustering para cualquier eps
- **HDBSCAN:**
  - Versión jerárquica basada en densidad
  - Más robusto a parámetros
  - Selecciona clusters por estabilidad
- **Implementación:**

```
from sklearn.cluster import DBSCAN

dbscan = DBSCAN(eps=0.5, min_samples=5)
labels = dbscan.fit_predict(X_scaled)
# -1 indica outliers

# HDBSCAN (librer a aparte)
import hdbscan
clusterer = hdbscan.HDBSCAN(min_cluster_size=5)
labels = clusterer.fit_predict(X_scaled)
```

## 2.4 Clustering Basado en Distribuciones

- **Gaussian Mixture Models (GMM):**
  - Asume que datos generados por mezcla de Gaussianas
  - Cada cluster es una distribución normal:

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x|\mu_k, \Sigma_k)$$

  - **EM Algorithm (Expectation-Maximization):**
    1. E-step: probabilidad de pertenencia a cada cluster
    2. M-step: actualizar parámetros $(\pi_k, \mu_k, \Sigma_k)$
  - **Ventajas:**
    - Clustering "suave"(probabilidades de pertenencia)
    - Clusters elípticos (no solo esféricos)
    - Puede modelar clusters de diferentes tamaños
  - **Limitaciones:**
    - Requiere asumir número de componentes
    - Puede converger a óptimos locales
    - Sensible a inicialización
  - **Covarianza types:**
    - 'full': cada cluster su propia matriz (flexible)
    - 'tied': todos comparten misma matriz
    - 'diag': diagonal (independencia condicional)
    - 'spherical': esférica (isotrópica)
- **Bayesian Gaussian Mixture:**
  - Versión bayesiana con prior Dirichlet
  - Selección automática de componentes
  - Menos overfitting
- **Implementación:**

```
from sklearn.mixture import GaussianMixture

gmm = GaussianMixture(n_components=5, covariance_type='full', random_state=42)
gmm.fit(X_scaled)
labels = gmm.predict(X_scaled)
probs = gmm.predict_proba(X_scaled)  # probabilidades "suaves"
```

## 2.5 Clustering Avanzado y Especializado

- **Spectral Clustering:**
  - Usa la matriz de similitud (grafos)
  - Proyecta en espacio de eigenvectores
  - Bueno para clusters no convexos
  - Costoso para grandes datasets
- **BIRCH (Balanced Iterative Reducing and Clustering):**
  - Diseñado para grandes datasets
  - Construye CF-tree (Clustering Feature)
  - Escalable, una sola pasada

- **Mean Shift:**
  - Basado en densidad (modas)
  - No requiere k
  - Ventana de ancho de banda crítica
  - Lento para datos grandes
- **Affinity Propagation:**
  - Mensajes entre puntos para elegir .exemplars"
  - No requiere k
  - Lento ($O(n^2)$)
- **Clustering para datos de alta dimensionalidad:**
  - Subspace clustering (CLIQUE)
  - Proyección (PROCLUS)
  - Co-clustering (biclustering)

# 3 Determinación del Número de Clusters (k)

## 3.1 Métodos Heurísticos

- **Método del Codo (Elbow Method):**
  - Graficar inercia (suma de distancias al cuadrado) vs k
  - Buscar punto donde disminución se estabiliza
  - Subjetivo, no siempre claro
- **Silhouette Analysis:**
  - Mide qué tan similar es un punto a su cluster vs otros
  - Rango: [-1, 1] (1 = bien agrupado)
  - Fórmula: $s(i) = \frac{b(i)-a(i)}{\text{máx}\{a(i),b(i)\}}$
  - Promedio global para cada k
  - Máximo sugiere mejor k
- **Calinski-Harabasz Index (Variance Ratio):**
  - Ratio de varianza entre-clusters / intra-cluster
  - Más alto = mejor
  - Asume clusters compactos y separados
- **Davies-Bouldin Index:**
  - Similitud promedio entre cada cluster y su más similar
  - Más bajo = mejor
  - No asume formas específicas
- **Gap Statistic:**
  - Compara inercia con datos uniformes (null reference)
  - Busca k que maximice "gap"
  - Más robusto pero costoso

### 3.2 Métodos Específicos por Algoritmo

- **Para clustering jerárquico:**
  - Inspección visual del dendrograma
  - Cortar en alturas con grandes saltos
- **Para DBSCAN:**
  - No requiere k, pero requiere eps y minPts
  - k-distance graph: buscar rodilla.en distancias
- **Para GMM:**
  - AIC (Akaike Information Criterion)
  - BIC (Bayesian Information Criterion)
  - Penalizan complejidad, menor es mejor

### 3.3 Validación Cruzada para Clustering

- **Estabilidad de clusters:**
  - Submuestrear datos, clusterizar, comparar resultados
  - Adjusted Rand Index (ARI) entre repeticiones
  - Mayor estabilidad sugiere mejor k
- **Prediction strength:**
  - Entrenar en train, predecir en test
  - Qué tan consistentes son las asignaciones

## 4 Evaluación de Clustering

### 4.1 Métricas Internas (sin ground truth)

- **Cohesión intra-cluster:**
  - Inercia (k-means)
  - Distancia promedio al centroide
  - Diámetro del cluster
- **Separación entre-clusters:**
  - Distancia entre centroides
  - Distancia mínima entre puntos de diferentes clusters
- **Métricas compuestas:**
  - Silhouette Score (mencionado)
  - Calinski-Harabasz
  - Davies-Bouldin
  - Dunn Index: mínima separación / máximo diámetro
- **Visualización de evaluación:**
  - Silhouette plot por cluster
  - Matriz de distancias ordenada por cluster

## 4.2 Métricas Externas (con ground truth)

- **Cuando hay etiquetas verdaderas:**
  - Adjusted Rand Index (ARI): -1 a 1, corregido por azar
  - Mutual Information (NMI): Normalized Mutual Information
  - Homogeneity: cada cluster contiene solo una clase
  - Completeness: todos los miembros de clase en mismo cluster
  - V-measure: media armónica de homogeneidad y completitud
  - Fowlkes-Mallows Index
- **Comparación:**
  - ARI y NMI son los más usados
  - ARI penaliza más el desorden

## 4.3 Validación Visual

- **Reducción de dimensionalidad para visualización:**
  - PCA (2D/3D) con color por cluster
  - t-SNE: preserva vecindarios locales
  - UMAP: más rápido, preserva estructura global
- **Diagnóstico visual:**
  - ¿Los clusters se ven separados?
  - ¿Hay overlap significativo?
  - ¿Los outliers son identificados?
- **Parallel coordinates:**
  - Visualizar perfiles de clusters
  - Líneas coloreadas por cluster
  - Útil para interpretar diferencias

# 5 Interpretación y Perfilado de Clusters

## 5.1 Caracterización de Clusters

- **Estadísticas descriptivas por cluster:**
  - Media, mediana, desviación por variable
  - Boxplots comparativos
  - Radar charts (para comparar perfiles)
- **Importancia de variables para clusters:**
  - ANOVA para cada variable (cluster como factor)
  - ¿Qué variables discriminan más?
  - Test de Kruskal-Wallis (no paramétrico)
- **Visualización de perfiles:**

```
# Perfil de clusters (centroides normalizados)
cluster_profile = pd.DataFrame(kmeans.cluster_centers_,
                               columns=feature_names)
sns.heatmap(cluster_profile, annot=True, cmap='coolwarm')
```

### 5.2 Naming y Descripción de Segmentos

- **Estrategias:**
  - Basado en variables dominantes (ej. "Jóvenes de altos ingresos")
  - Basado en tamaño (ej. Çluster mayoritario")
  - Basado en comportamiento (ej. Çompradores frecuentes")
- **Documentación de segmentos:**
  - Tamaño (número y porcentaje)
  - Perfil demográfico/conductual
  - Variables clave que los definen
  - Valor para negocio

### 5.3 Validación con Stakeholders

- **Interpretabilidad de negocio:**
  - ¿Los segmentos tienen sentido lógico?
  - ¿Son accionables (se puede diseñar estrategia)?
  - ¿Son estables en el tiempo?
- **Test de significancia práctica:**
  - Diferencias suficientemente grandes para ser útiles
  - Tamaños de efecto (Cohen's d)

## 6 Problemas Comunes y Soluciones

### 6.1 Escala y Normalización

- **Problema:** variables con diferentes unidades dominan
- **Solución:** siempre estandarizar (StandardScaler)
- **Excepción:** si las magnitudes son informativas

### 6.2 Maldición de la Dimensionalidad

- **Problema:** en alta dimensión, distancias se vuelven similares
- **Soluciones:**
  - Reducción de dimensionalidad (PCA, selección)
  - Subspace clustering
  - Usar distancias basadas en correlación
  - Feature selection basada en varianza

### 6.3 Clusters de Diferentes Tamaños y Densidades

- **Problema:** k-means asume tamaños similares
- **Soluciones:**
  - DBSCAN para densidades variables
  - GMM para diferentes tamaños
  - Spectral clustering para formas complejas

### 6.4 Outliers y Ruido

- **Problema:** outliers pueden distorsionar clusters
- **Soluciones:**
  - DBSCAN (identifica outliers como -1)
  - Detectar y eliminar outliers previamente
  - K-medoids (más robusto)

### 6.5 Inicialización y Estabilidad

- **Problema:** algoritmos como k-means dependen de inicialización
- **Soluciones:**
  - K-means++ para mejor inicialización
  - Ejecutar múltiples veces con diferentes semillas
  - Seleccionar resultado con menor inercia
  - n_init en sklearn (por defecto 10)

## 7 Técnicas Avanzadas

### 7.1 Clustering con Datos Mixtos

- **K-prototypes:** combina k-means (numéricas) y k-modes (categóricas)
- **FAMD (Factor Analysis of Mixed Data):**
  - Reduce dimensionalidad de datos mixtos
  - Luego aplicar clustering
- **Gower distance + PAM:**
  - Calcular matriz de distancia Gower
  - Aplicar PAM (K-medoids)

### 7.2 Clustering Jerárquico con Grandes Datasets

- **Muestreo previo:** clusterizar muestra, asignar resto
- **BIRCH:** diseñado para escalar
- **CHAMELEON:** grafos + particionamiento
- **CURE:** usa múltiples representantes por cluster

### 7.3 Ensamblado de Clustering

- **Concepto:** combinar múltiples clustering para mayor estabilidad
- **Técnicas:**
  - Consensus clustering (votación)
  - Evidence Accumulation (matriz de co-ocurrencia)
  - Bagging de clustering

### 7.4 Clustering con Restricciones (Semi-supervisado)

- **Must-link / Cannot-link constraints:**
  - COBWEB, COP-KMEANS
  - Guían el clustering con conocimiento previo
- **Seeding:** usar etiquetas conocidas para inicializar

### 7.5 Clustering Temporal y de Series

- **Shape-based:** DTW (Dynamic Time Warping) distance
- **Feature-based:** extraer estadísticos, luego clustering
- **Model-based:** ajustar modelos por serie, clusterizar parámetros

### 7.6 Clustering en Streaming

- **Algoritmos online:** StreamKM++, BOCF
- **Window-based:** clustering en ventanas deslizantes
- **Aplicaciones:** monitoreo en tiempo real

## 8 Casos de Uso y Aplicaciones

### 8.1 Segmentación de Clientes (Marketing)

- **Variables típicas:** RFM (Recencia, Frecuencia, Monto), demográficas
- **Objetivo:** estrategias diferenciadas por segmento
- **Acciones:** campañas específicas, personalización

### 8.2 Segmentación de Productos

- **Variables:** atributos, precios, ventas
- **Objetivo:** categorización, recomendación

### 8.3 Detección de Anomalías

- **Enfoque:** outliers como clusters pequeños o ruido
- **Aplicaciones:** fraude, intrusiones, fallos
- **Algoritmos:** DBSCAN, Isolation Forest (especializado)

### 8.4 Compresión y Cuantización

- **Uso:** representar datos por centroides (codebooks)
- **Aplicación:** compresión de imágenes (k-means en RGB)

### 8.5 Análisis de Imágenes y Visión

- **Segmentación de imágenes:** clusters de píxeles
- **Bag of Visual Words:** clusters de descriptores

### 8.6 Bioinformática y Genómica

- **Expresión génica:** genes con perfiles similares
- **Filogenética:** jerárquico para especies

### 8.7 Análisis de Redes Sociales

- **Detección de comunidades:** spectral clustering en grafos
- **Perfiles de usuarios:** por comportamiento

## 9 Producción y Mantenimiento

### 9.1 Asignación de Nuevos Puntos

- **Modelos con predict:** k-means, GMM
  - Asignar al centroide más cercano
  - Probabilidades para GMM
- **Modelos sin predict nativo:**
  - Entrenar clasificador supervisado sobre etiquetas
  - Usar distancia a centroides/exemplars
  - KNN con los puntos originales
- **Consideraciones:**
  - Nuevos puntos pueden no pertenecer a ningún cluster
  - Definir umbral de distancia máxima
  - Crear categoría .ºtros"para outliers

### 9.2 Serialización y Despliegue

- **Guardar modelo:** joblib/pickle
- **Guardar centroides:** para asignación rápida
- **API de inferencia:** asignar nuevo punto a cluster

### 9.3 Monitoreo de Estabilidad Temporal

- **Drift de clusters:**
  - ¿Los centroides se desplazan?
  - ¿Aparecen nuevos tipos de clientes?
  - ¿Desaparecen segmentos?
- **Re-clustering periódico:**
  - Re-evaluar cada cierto tiempo
  - Comparar con segmentación anterior
  - Ajustar estrategias de negocio
- **Métricas de seguimiento:**
  - Distribución de tamaños de clusters
  - Perfiles promedio por cluster
  - Porcentaje de no asignados (outliers)

### 9.4 Actualización del Modelo

- **Reentrenamiento completo:** periódico
- **Actualización incremental:** para streaming
- **Versionado de segmentaciones:** mantener histórico

## 10 Checklist de Implementación

- **Preparación de Datos**
  - ☐ Escalar/normalizar variables numéricas
  - ☐ Codificar categóricas (One-Hot, Gower)
  - ☐ Evaluar necesidad de reducción dimensional
  - ☐ Detectar y decidir manejo de outliers
- **Selección de Algoritmo**
  - ☐ ¿Tamaño del dataset? (escalabilidad)
  - ☐ ¿Forma esperada de clusters? (esféricos, arbitrarios)
  - ☐ ¿Necesito jerarquía? (dendrograma)
  - ☐ ¿Hay outliers? (DBSCAN vs k-means)
  - ☐ ¿Datos mixtos? (Gower + PAM, K-prototypes)
- **Determinación de k/Parámetros**
  - ☐ Probar múltiples k con método del codo
  - ☐ Calcular Silhouette para cada k
  - ☐ Evaluar métricas (Calinski, Davies-Bouldin)
  - ☐ Para DBSCAN: ajustar eps y minPts
  - ☐ Validar estabilidad con submuestreo
- **Evaluación**
  - ☐ Visualizar con PCA/t-SNE/UMAP
  - ☐ Calcular métricas internas
  - ☐ Analizar silhouette por punto
  - ☐ Si hay etiquetas, métricas externas (ARI, NMI)
- **Interpretación**
  - ☐ Calcular centroides/perfiles
  - ☐ Estadísticas descriptivas por cluster
  - ☐ Identificar variables discriminantes
  - ☐ Nombrar y documentar cada segmento
  - ☐ Validar con stakeholders de negocio
- **Producción**
  - ☐ Definir método de asignación para nuevos puntos
  - ☐ Establecer umbral de distancia para .ºtros”
  - ☐ Guardar modelo/centroides
  - ☐ Implementar API de asignación
  - ☐ Plan de monitoreo y re-clustering

## 11 Herramientas y Librerías Útiles

- **Scikit-learn:** KMeans, DBSCAN, GMM, Agglomerative, Spectral
- **Scipy:** clustering jerárquico, distancias
- **HDBSCAN:** clustering basado en densidad avanzado
- **Yellowbrick:** visualización de elbow, silhouette
- **kmodes / kprototypes:** para datos categóricos/mixtos
- **Prince:** FAMD para datos mixtos
- **ClusterEnsembles:** consensus clustering
- **DTW (dtaidistance):** para series temporales
- **TSNE / UMAP:** visualización de alta dimensión

## 12 Conclusiones y Buenas Prácticas

- **Estandarizar siempre:** especialmente para algoritmos basados en distancia
- **No hay "mejor.ªlgoritmo:** depende de la forma de datos y objetivo
- **El número de clusters es subjetivo:** combinar métodos estadísticos con interpretabilidad de negocio
- **Validar con stakeholders:** los segmentos deben tener sentido práctico
- **Documentar perfiles:** no basta con asignar etiquetas, hay que entender qué significan
- **Planificar mantenimiento:** los segmentos cambian con el tiempo
- **Outliers son información:** pueden representar nichos o anomalías valiosas
- **Visualizar siempre:** ayuda a comunicar y validar resultados

## 13 Apéndice: Comparativa de Algoritmos

| Algoritmo | Tipo | Requiere k | Forma clusters | Outliers | Escalabilidad |
|---|---|---|---|---|---|
| K-Means | Particional | Sí | Esféricos | Sensible | Muy buena |
| K-Medoids (PAM) | Particional | Sí | Esféricos | Robusto | Media |
| Hierárquico | Jerárquico | No | Variable | Sensible | Baja |
| DBSCAN | Densidad | No | Arbitraria | Detecta | Media |
| OPTICS | Densidad | No | Arbitraria | Detecta | Media |
| GMM | Distribucional | Sí | Elípticos | Probabilístico | Buena |
| Spectral | Grafos | Sí | Arbitraria | Sensible | Baja |
| BIRCH | Particional | Opcional | Esféricos | Detecta | Excelente |
| Mean Shift | Densidad | No | Arbitraria | Detecta | Baja |

Cuadro 1: Comparativa de algoritmos de clustering